HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN I

BÁO CÁO ĐỀ CƯƠNG THỰC HIỆN
ĐỀ TÀI MÔN THỰC TẬP CƠ SỞ

Giảng viên hướng dẫn : TS. Kim Ngọc Bách
Sinh viên thực hiện : Mã sinh viên
Nguyễn Việt Quang : B23DCCN691

Hà Nội - 2026

I. Giới thiệu dự án

Tên đề tài

Finetune mô hình BLIP theo bộ dữ liệu tiếng Việt và xây dựng hệ thống mô tả thế giới thực cho người khiếm thị.

Lý do chọn đề tài

Các mô hình Vision–Language hiện đại như BLIP cho thấy hiệu quả cao trong bài toán mô tả hình ảnh, tuy nhiên khả năng hỗ trợ tiếng Việt còn hạn chế. Bên cạnh đó, người khiếm thị tại Việt Nam vẫn thiếu các công cụ hỗ trợ tiếp cận thông tin trực quan bằng ngôn ngữ tự nhiên. Đề tài được lựa chọn nhằm tiếp cận công nghệ AI hiện đại và giải quyết một bài toán mang tính ứng dụng xã hội.

Ý nghĩa và tính ứng dụng

- Góp phần cải thiện khả năng mô tả hình ảnh tiếng Việt của mô hình BLIP
- Xây dựng demo hệ thống hỗ trợ người khiếm thị nhận biết môi trường xung quanh
- Phù hợp mục tiêu học phần: tiếp cận công nghệ mới và xây dựng ứng dụng thực tế

II. Cơ sở lý thuyết và công nghệ sử dụng

1. Mô hình ngôn ngữ-thị giác (Vision-Language Model)

Mô hình ngôn ngữ-thị giác (Vision-Language Model, VLM) là một loại mô hình trí tuệ nhân tạo kết hợp đồng thời khả năng xử lý hình ảnh và ngôn ngữ. Khác với các mô hình chỉ xử lý văn bản hay chỉ xử lý hình ảnh, VLM học được mối quan hệ giữa nội dung hình ảnh và mô tả ngôn ngữ, từ đó có thể thực hiện các bài toán đa phương thức như mô tả ảnh (captioning), trả lời câu hỏi dựa trên ảnh (VQA) và truy xuất ảnh-văn bản .

2. Bài toán mô tả ảnh (Image Captioning)

Mô tả ảnh là bài toán tạo ra một câu văn tự nhiên mô tả nội dung chính của hình ảnh. Đây là bài toán nằm ở giao điểm giữa thị giác máy tính và xử lý ngôn ngữ tự nhiên. Khác với các bài toán phân loại hay nhận diện đối tượng, mô tả ảnh yêu cầu mô hình không chỉ nhận biết các đối tượng mà còn diễn đạt mối quan hệ giữa chúng bằng câu chữ tự nhiên .

3. BLIP: Bootstrapping Language-Image Pre-training

BLIP (Bootstrapping Language-Image Pre-training) là một khung đa phương thức (multimodal) được thiết kế để học biểu diễn chung giữa hình ảnh và ngôn ngữ. Điểm đặc biệt của BLIP là khả năng xử lý các nhiệm vụ liên quan đến hình ảnh và văn bản trong một mô hình duy nhất. BLIP sử dụng kỹ thuật *bootstrapping* để tận dụng các dữ liệu ảnh-văn bản thô (noisy web data): mô hình sinh mô tả cho ảnh (captioner) và lọc các mô tả không phù hợp (filter) nhằm cải thiện chất lượng dữ liệu huấn luyện . Chính nhờ cách tiếp cận này, BLIP đạt được hiệu suất cao trên nhiều tác vụ như truy xuất ảnh-văn bản (image-text retrieval), mô tả ảnh (image captioning) và trả lời câu hỏi trực quan (visual question answering) so với các phương pháp trước đó .

Các mô hình tiền huấn luyện như BLIP có lợi thế vì chúng cho phép tinh chỉnh (*finetune*) trên bộ dữ liệu cụ thể của ngôn ngữ hoặc ứng dụng mục tiêu mà không cần huấn luyện lại toàn bộ mô hình từ đầu. Việc tinh chỉnh mô hình BLIP với dữ liệu ảnh-chú thích tiếng Việt sẽ giúp cải thiện khả năng mô tả phù hợp với ngôn ngữ và cấu trúc ngữ nghĩa của tiếng Việt trong ứng dụng thực tế của dự án.

4. Finetune mô hình

Finetune là quá trình điều chỉnh mô hình đã được tiền huấn luyện trên một tập dữ liệu lớn sang một tác vụ hoặc ngôn ngữ cụ thể bằng cách tiếp tục huấn luyện với một bộ dữ liệu mục tiêu nhỏ hơn. Trong dự án này, finetune BLIP nhằm mục tiêu làm cho mô hình hiểu và mô tả hình ảnh bằng tiếng Việt tốt hơn so với mô hình BLIP gốc chỉ được huấn luyện chủ yếu bằng dữ liệu tiếng Anh hoặc dữ liệu đa ngôn ngữ sẵn có .

2.5. Công nghệ và thư viện sử dụng

Ứng dụng finetune và triển khai mô hình BLIP thường sử dụng các công nghệ học sâu hiện đại như sau:

- Framework học sâu: PyTorch – hỗ trợ xây dựng và huấn luyện các mô hình mạng nơ-ron phức tạp.
- Thư viện mô hình: Transformers/LAVIS – cung cấp các mô hình BLIP tiền huấn luyện và các công cụ để finetune.
- Xử lý hình ảnh: OpenCV hoặc Pillow để tải và tiền xử lý ảnh đầu vào.
  Các công cụ này là tiêu chuẩn trong nghiên cứu và phát triển các hệ thống thị giác-ngôn ngữ hiện đại và thường được sử dụng kết hợp để xây dựng các pipeline finetune và demo ứng dụng.

Công nghệ dự kiến

- Ngôn ngữ: Python
- Framework: PyTorch
- Thư viện hỗ trợ: HuggingFace Transformers, OpenCV
- Môi trường huấn luyện: GPU cá nhân hoặc nền tảng cloud

III. Phân tích yêu cầu dự án

1. Yêu cầu chức năng

- Nhận ảnh từ camera hoặc tập ảnh có sẵn
- Sinh mô tả hình ảnh bằng tiếng Việt
- Hiển thị mô tả dưới dạng văn bản (định hướng mở rộng sang giọng nói)

2. Yêu cầu phi chức năng

- Hệ thống hoạt động ổn định ở mức demo
- Mô hình sinh mô tả đúng ngữ nghĩa cơ bản
- Thời gian phản hồi chấp nhận được, không yêu cầu real-time nghiêm ngặt

3. Phạm vi dự án

- Finetune mô hình BLIP trên bộ dữ liệu tiếng Việt quy mô vừa

- Xây dựng demo hệ thống minh họa
- Không tập trung tối ưu hóa quy mô lớn hay triển khai thương mại

IV. Kế hoạch thực hiện dự án

Giai đoạn 1: Khảo sát và chuẩn bị

- Tìm hiểu mô hình BLIP và các nghiên cứu liên quan
- Khảo sát các dataset image-caption tiếng Việt
- Chuẩn bị môi trường phát triển

Giai đoạn 2: Xây dựng dữ liệu và mô hình

- Thu thập và tiền xử lý dữ liệu
- Thiết kế pipeline huấn luyện
- Finetune mô hình BLIP với dữ liệu tiếng Việt

Giai đoạn 3: Đánh giá và cải tiến

- Đánh giá kết quả sinh mô tả
- Phân tích lỗi và điều chỉnh tham số
- Hoàn thiện mô hình

Giai đoạn 4: Xây dựng hệ thống demo và báo cáo

- Xây dựng ứng dụng demo mô tả hình ảnh
- Hoàn thiện báo cáo cuối kỳ
- Chuẩn bị slide và demo sản phẩm

V. Kết quả dự kiến

- Mô hình BLIP được finetune cho tiếng Việt
- Ứng dụng demo mô tả hình ảnh phục vụ người khiếm thị
- Báo cáo kỹ thuật và mã nguồn theo đúng cấu trúc GitHub yêu cầu của học phần

Tài liệu tham khảo

1. Li, J., Li, D., Xiong, C., & Hoi, S. C. H. (2022). BLIP: Bootstrapping Language-Image Pre-training for Unified Vision-Language Understanding and Generation. *arXiv preprint arXiv:2201.12086*.
2. Wikipedia. "Vision-language model". Truy cập tại https://en.wikipedia.org/wiki/Vision-language_model (ngày truy cập 26/02/2026).
3. OpenVINO. "Visual Question Answering and Image Captioning using BLIP Notebooks". OpenVINO official documentation. Truy cập tại https://docs.openvino.ai/2023.3/notebooks/233-blip-convert-with-output.html (ngày truy cập 26/02/2026).
4. Kiemtratailieu.vn. "Cách trích dẫn tài liệu tham khảo đúng chuẩn". Truy cập tại https://kiemtratailieu.vn/blog/cach-trich-dan-tai-lieu-tham-khao-dung-chuan/ (ngày truy cập 26/02/2026).