

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN I



BÁO CÁO HÀNG TUẦN MÔN
THỰC TẬP CƠ SỞ

Giảng viên hướng dẫn	: TS. Kim Ngọc Bách
Sinh viên thực hiện	: Mã sinh viên
Nguyễn Việt Quang	: B23DCCN691

Hà Nội – 2026

I. Tối ưu hóa Tokenizer tiếng Việt, cải thiện Pipeline sinh caption và đánh giá mô hình

1. Mở đầu

Tiếp nối giai đoạn huấn luyện chính thức (Full Finetuning) trên nền tảng Kaggle đã được thực hiện ở tuần trước, trong tuần này nội dung tập trung vào việc giải quyết triệt để ba vấn đề cốt lõi còn tồn đọng của pipeline: vấn đề Tokenizer không hỗ trợ đầy đủ tiếng Việt có dấu, hiện tượng lặp từ và mode collapse trong quá trình sinh caption, và hiệu năng tính toán hạn chế khi chỉ tận dụng một trong hai GPU Tesla T4 trên Kaggle.

Cụ thể, ở vòng huấn luyện trước, mặc dù mô hình đã có thể sinh ra caption tiếng Việt có ngữ nghĩa tương đối hợp lý, đầu ra vẫn còn tồn tại một số vấn đề nghiêm trọng. Tokenizer mặc định của BLIP sử dụng BERT wordpiece được thiết kế cho tiếng Anh, có cơ chế loại bỏ dấu (strip accents) khiến các ký tự tiếng Việt có dấu không được biểu diễn chính xác. Ngoài ra, caption sinh ra có hiện tượng lặp lại từ màu sắc liên tục và xuất hiện tiền tố lạ "Shakhtar_Donetsk" ở đầu mỗi câu, cho thấy decoder đang bị lệch phân phối sinh ngôn ngữ. Bên cạnh đó, hệ thống mới chỉ sử dụng một GPU trong khi Kaggle cấp hai GPU Tesla T4, dẫn đến lãng phí tài nguyên tính toán đáng kể.

Vì vậy, trong tuần này, em tiến hành thay thế toàn bộ Tokenizer tiếng Anh sang PhoBERT, một mô hình ngôn ngữ được huấn luyện chuyên biệt cho tiếng Việt từ VinAI Research, đồng thời điều chỉnh lại các tham số sinh caption và cấu hình lại pipeline để tận dụng cả hai GPU. Kết quả thu được là một pipeline hoàn chỉnh với khả năng sinh caption tiếng Việt có dấu đúng chuẩn và bộ chỉ số đánh giá định lượng đầu tiên của đề tài.

2. Mục tiêu thực hiện

Mục tiêu cụ thể của tuần này bao gồm bốn phần chính.

Phần thứ nhất là thay thế Tokenizer BERT tiếng Anh bằng PhoBERT của VinAI, đảm bảo mô hình có thể học và sinh đúng toàn bộ ký tự tiếng Việt có dấu thanh. Phần này bao gồm việc cấu hình lại các token đặc biệt `bos_token` và `eos_token` của PhoBERT để tương thích với kiến trúc decoder của BLIP, đồng thời resize lại embedding layer của `text_decoder` để phù hợp với kích thước vocabulary mới (khoảng 64.000 token).

Phần thứ hai là điều chỉnh tham số sinh caption nhằm khắc phục hiện tượng lặp từ và mode collapse. Cụ thể, bổ sung tham số `no_repeat_ngram_size` và `repetition_penalty`

vào hàm generate để ngăn mô hình rơi vào vòng lặp sinh cùng một từ hoặc cụm từ nhiều lần liên tiếp.

Phần thứ ba là cấu hình DataParallel để tận dụng cả hai GPU Tesla T4 trên Kaggle, từ đó tăng effective batch size và rút ngắn thời gian huấn luyện. Đây là bước tối ưu hóa phần cứng quan trọng để đảm bảo tiến độ huấn luyện trong khung thời gian còn lại của đề tài.

Phần thứ tư là hoàn thiện pipeline đánh giá và đo lường chỉ số BLEU-4, ROUGE-L và METEOR trên toàn bộ tập test 10.001 mẫu, qua đó có được kết quả định lượng đầu tiên phản ánh chất lượng thực sự của mô hình sau khi khắc phục vấn đề Tokenizer.

3. Môi trường và thiết lập thực hiện

Toàn bộ quá trình huấn luyện và đánh giá trong tuần này được thực hiện trên nền tảng Kaggle Notebook với cấu hình hai GPU NVIDIA Tesla T4, mỗi GPU có 15GB VRAM, tổng cộng 30GB VRAM khả dụng. Môi trường sử dụng Python 3.12, PyTorch, Transformers (Hugging Face) và thư viện evaluate để tính toán các chỉ số đánh giá. Dữ liệu đầu vào là bộ dữ liệu UIT-OpenViLC đã được tiền xử lý và resize về kích thước 384x384 từ các tuần trước, được lưu trữ dưới dạng Kaggle Dataset để đảm bảo tốc độ đọc dữ liệu ổn định trong quá trình huấn luyện.

4. Nội dung thực hiện chi tiết

4.1. Thay thế Tokenizer BERT sang PhoBERT

Nguyên nhân gốc rễ của vấn đề tiếng Việt sai dấu trong các tuần trước đã được xác định là do Tokenizer BERT mặc định của BLIP sử dụng cơ chế wordpiece với tùy chọn strip_accents, vốn được thiết kế để chuẩn hóa văn bản tiếng Anh. Cơ chế này loại bỏ toàn bộ dấu thanh và dấu phụ ra khỏi các ký tự Unicode, khiến các từ tiếng Việt bị biến dạng hoàn toàn. Ngoài ra, việc thêm thủ công các từ tiếng Việt vào vocab bằng phương thức add_tokens trong các phiên bản pipeline trước cũng không khắc phục được vấn đề này, vì các token mới có embedding được khởi tạo ngẫu nhiên và không có tri thức ngôn ngữ nền.

Giải pháp được triển khai trong tuần này là thay thế hoàn toàn Tokenizer bằng PhoBERT của VinAI Research, một mô hình ngôn ngữ được pretrain chuyên biệt cho tiếng Việt với kho ngữ liệu 20GB từ các nguồn tin tức và văn bản tiếng Việt đa dạng. PhoBERT sử dụng thuật toán BPE (Byte Pair Encoding) và không có bước loại bỏ dấu, đảm bảo

toàn bộ ký tự tiếng Việt được biểu diễn và xử lý chính xác. Vocabulary của PhoBERT có khoảng 64.000 token, bao phủ đầy đủ các âm tiết tiếng Việt phổ biến.

Để tích hợp PhoBERT vào kiến trúc BLIP, cần thực hiện ba bước kỹ thuật quan trọng. Đầu tiên, ánh xạ lại các token đặc biệt của PhoBERT sang chuẩn của BLIP: token <s> (CLS) được dùng làm bos_token và token </s> (SEP) được dùng làm eos_token. Tiếp theo, thay thế processor.tokenizer bằng vi_tokenizer để toàn bộ quy trình mã hóa văn bản sử dụng PhoBERT. Cuối cùng, gọi model.text_decoder.resize_token_embeddings(len(vi_tokenizer)) để điều chỉnh lại kích thước embedding layer của text decoder cho phù hợp với vocabulary mới.

4.2. Điều chỉnh tham số sinh caption

Sau khi thay Tokenizer, vẫn còn tồn tại hai vấn đề trong quá trình sinh caption. Thứ nhất là hiện tượng lặp từ màu sắc liên tục như "vàng vàng vàng trắng vàng" mà nguyên nhân là decoder không có cơ chế ngăn chặn việc tái sử dụng n-gram đã sinh ra. Thứ hai là mode collapse: toàn bộ các ảnh đều ra cùng một caption giống nhau, cho thấy decoder đang thiên về một phân phối hẹp cố định.

Để khắc phục, hai tham số được bổ sung vào hàm generate. Tham số no_repeat_ngram_size=3 ngăn model sinh lại bất kỳ chuỗi 3-gram nào đã xuất hiện trong câu, loại bỏ hiệu quả hiện tượng lặp từ. Tham số repetition_penalty=1.5 áp dụng hệ số phạt cho xác suất của các token đã xuất hiện trước đó, giúp decoder đa dạng hóa lựa chọn từ ngữ. Ngoài ra, num_beams được tăng lên 4 để beam search có nhiều hướng tìm kiếm hơn, cải thiện chất lượng câu sinh ra về mặt ngữ nghĩa và ngữ pháp.

4.3. Cấu hình DataParallel cho hai GPU

Một trong những vấn đề kỹ thuật được phát hiện trong quá trình theo dõi huấn luyện là hệ thống chỉ sử dụng một GPU trong khi Kaggle cấp tới hai GPU Tesla T4. GPU thứ nhất chạy gần 100% tải trong khi GPU thứ hai hoàn toàn nhàn rỗi. Nguyên nhân là PyTorch mặc định chỉ sử dụng thiết bị đầu tiên trong danh sách CUDA trừ khi được cấu hình rõ ràng để phân tán.

Giải pháp là bọc mô hình trong torch.nn.DataParallel ngay sau khi load model và chuyển sang GPU. DataParallel tự động chia batch thành các mini-batch nhỏ hơn, gửi mỗi phần sang một GPU riêng biệt để tính forward pass song song, sau đó thu thập gradient về GPU chính để cập nhật trọng số. Điều này cần chú ý một điểm kỹ thuật quan trọng: khi

sử dụng DataParallel, mọi thao tác gọi trực tiếp vào các thuộc tính nội bộ của model như vision_model, text_decoder hay generate phải thông qua model.module thay vì model trực tiếp, vì DataParallel bọc model trong một lớp wrapper.

4.4. Huấn luyện với PhoBERT Tokenizer và đánh giá trên tập test

Sau khi hoàn thiện các điều chỉnh trên, mô hình được huấn luyện lại từ đầu với PhoBERT Tokenizer. Quá trình huấn luyện sử dụng AdamW optimizer với weight_decay=0.01, cosine scheduler với 10% warmup steps và early stopping với patience=3. Vision encoder được giữ nguyên ở trạng thái đóng băng (frozen) trong toàn bộ quá trình huấn luyện để tránh lỗi tràn bộ nhớ GPU và vì kiến trúc visual của BLIP đã được pretrain rất tốt trên lượng dữ liệu lớn. Chỉ text decoder và các lớp cross-attention được cập nhật trọng số.

Sau khi huấn luyện, pipeline đánh giá được chạy trên toàn bộ 10.001 mẫu của tập test. Quá trình sinh caption sử dụng beam search với num_beams=4, no_repeat_ngram_size=3 và repetition_penalty=1.5. Các câu sinh ra được đối chiếu với caption tham chiếu gốc thông qua thư viện evaluate của Hugging Face để tính toán ba chỉ số chuẩn trong bài toán image captioning.

5. Kết quả thực nghiệm

5.1. Chất lượng caption sinh ra sau khi dùng PhoBERT

So sánh trực tiếp với kết quả của các tuần trước, caption sinh ra sau khi tích hợp PhoBERT đã có sự cải thiện rõ rệt về mặt ngôn ngữ. Các câu sinh ra có dấu thanh tiếng Việt đầy đủ và đúng chuẩn, không còn hiện tượng mất dấu hay sai dấu như trong pipeline sử dụng BERT. Nội dung caption cũng có độ đa dạng tốt hơn giữa các ảnh, không còn hiện tượng toàn bộ ảnh ra cùng một câu giống nhau như trong các thử nghiệm trước.

Một số ví dụ caption trên tập test cho thấy mô hình đã có khả năng nhận diện và mô tả các thực thể quan trọng trong ảnh như người phụ nữ, cửa hàng, biển hiệu, cây thông, tòa nhà một cách tương đối chính xác. Mô hình cũng mô tả được các thuộc tính màu sắc và bối cảnh không gian ở mức hợp lý, phù hợp với đặc trưng ngôn ngữ phổ biến trong bộ dữ liệu UIT-OpenViIC.

Tuy nhiên, một số caption vẫn còn xuất hiện tiền tố lạ "Shakhtar_Donetsk" ở đầu câu. Qua phân tích, nguyên nhân được xác định là tiền tố này tồn tại trong dữ liệu CSV gốc ở phần tên file ảnh và đã bị lẫn vào cột caption trong quá trình đọc dữ liệu. Đây là vấn

đề của bước tiền xử lý dữ liệu, không phải của Tokenizer hay kiến trúc mô hình, và cần được xử lý ở cấp độ làm sạch CSV trước khi huấn luyện lại.

5.2. Kết quả đánh giá định lượng

Sau khi chạy pipeline đánh giá đầy đủ trên 10.001 mẫu tập test, bộ chỉ số định lượng đầu tiên của đề tài được ghi nhận như sau:

BLEU-4 Score: 6.18

ROUGE-L Score: 34.21

METEOR Score: 34.62

Đây là bộ chỉ số thu được từ mô hình BLIP-base được finetune với PhoBERT Tokenizer trên toàn bộ tập train của UIT-OpenViC, với vision encoder được giữ nguyên và chỉ cập nhật text decoder. Điểm BLEU-4 ở mức 6.18 phản ánh thực tế rằng mô hình chỉ với text decoder được học lại từ đầu (do thay toàn bộ Tokenizer) trên khoảng 40.000 mẫu huấn luyện vẫn còn khoảng cách so với các mô hình tiếng Việt được tối ưu sâu hơn. Tuy nhiên, chỉ số ROUGE-L và METEOR ở mức trên 34 cho thấy mô hình đã học được cấu trúc câu và phân phối từ vựng tiếng Việt ở mức tương đối tốt, phản ánh nội dung ảnh ở mức độ ngữ nghĩa tổng quát.

Cần lưu ý rằng tiền tố "Shakhtar_Donetsk" xuất hiện trong một phần caption sinh ra có ảnh hưởng tiêu cực đến điểm BLEU-4, vì đây là các token hoàn toàn không khớp với caption tham chiếu. Nếu loại bỏ được vấn đề dữ liệu này trong lần huấn luyện tiếp theo, điểm BLEU-4 dự kiến sẽ cải thiện đáng kể.

6. Nhận xét và đánh giá

Trong tuần này, pipeline finetune mô hình BLIP tiếng Việt đã được nâng cấp toàn diện và đạt đến mức hoàn chỉnh về mặt kỹ thuật. Việc tích hợp PhoBERT Tokenizer là bước quyết định giải quyết được vấn đề cốt lõi về biểu diễn tiếng Việt có dấu, một vấn đề mà các phương án khắc phục thủ công như add_tokens trong các phiên bản trước đều không giải quyết được triệt để do bản chất của BERT wordpiece không tương thích với hệ thống thanh điệu của tiếng Việt.

Tuy nhiên, việc thay toàn bộ Tokenizer đồng nghĩa với việc toàn bộ embedding của text decoder phải được học lại từ đầu, vì PhoBERT có vocabulary hoàn toàn khác với BERT. Điều này giải thích tại sao loss ở epoch đầu rất cao (khoảng 11, tương đương với dự đoán ngẫu nhiên trên vocabulary ~64.000 token) và mô hình cần nhiều epoch hơn để

hội tụ so với trường hợp chỉ tinh chỉnh trên Tokenizer cũ. Đây là đánh đổi có chủ ý và được chấp nhận, vì tính chính xác về ngôn ngữ của đầu ra quan trọng hơn việc rút ngắn thời gian hội tụ.

Vấn đề tiền tố "Shakhtar_Donetsk" trong caption là bài học quan trọng về tầm quan trọng của bước kiểm tra và làm sạch dữ liệu kỹ lưỡng trước khi huấn luyện. Dù bộ dữ liệu UIT-OpenViC đã được đánh giá là tương đối sạch ở báo cáo ngày 28-03, vấn đề này cho thấy cần thêm bước kiểm tra nội dung cột caption để phát hiện các trường hợp tên file ảnh hoặc metadata bị lẫn vào dữ liệu văn bản.

7. Kết luận

Trong tuần này, em đã hoàn thành việc tích hợp PhoBERT Tokenizer vào pipeline finetune BLIP, điều chỉnh các tham số sinh caption để khắc phục hiện tượng lặp từ và mode collapse, cấu hình DataParallel để tận dụng cả hai GPU Tesla T4 trên Kaggle, và thu được bộ chỉ số đánh giá định lượng đầu tiên của đề tài với BLEU-4 đạt 6.18, ROUGE-L đạt 34.21 và METEOR đạt 34.62 trên tập test 10.001 mẫu.

Đây là kết quả quan trọng đánh dấu sự hoàn thiện về mặt kỹ thuật của toàn bộ pipeline finetune, từ bước tiền xử lý dữ liệu, xây dựng dataset và dataloader, huấn luyện với mixed precision, validation, checkpointing, đến inference và đánh giá định lượng. Trong thời gian còn lại của đề tài, em sẽ tập trung vào việc làm sạch vấn đề dữ liệu tiền tố "Shakhtar_Donetsk", huấn luyện lại để có kết quả sạch hơn, và bắt đầu xây dựng ứng dụng demo mô tả hình ảnh phục vụ người khiếm thị theo đúng định hướng đã đề ra trong đề cương.