HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN I

BÁO CÁO HẰNG TUẦN MÔN
THỰC TẬP CƠ SỞ

Giảng viên hướng dẫn : TS. Kim Ngọc Bách
Sinh viên thực hiện : Mã sinh viên
Nguyễn Việt Quang : B23DCCN691

Hà Nội – 2026

I. Tiền xử lý và chuẩn hóa bộ dataset UIT-OpenViIC cho bài toán image captioning tiếng Việt

1. Mở đầu

Trong tiến trình thực hiện đề tài **Finetune mô hình BLIP theo bộ dữ liệu tiếng Việt và xây dựng hệ thống mô tả thế giới thực cho người khiếm thị**, sau khi đã khảo sát các bộ dữ liệu image captioning tiếng Việt và thử nghiệm bước đầu mô hình BLIP tiền huấn luyện, một bước trung gian rất quan trọng trước khi bước sang giai đoạn huấn luyện là tiến hành tiền xử lý và chuẩn hóa dữ liệu.

Về bản chất, với bài toán image captioning, mô hình không chỉ học từ hình ảnh mà còn học từ mối liên kết giữa hình ảnh và câu mô tả. Vì vậy, chất lượng của dữ liệu ảnh – caption ảnh hưởng trực tiếp đến khả năng học biểu diễn thị giác, biểu diễn ngôn ngữ cũng như mức độ căn chỉnh giữa hai miền dữ liệu. Điều này cũng phù hợp với phần nghiên cứu dataset đã thực hiện trước đó, trong đó đã nhấn mạnh rằng trước khi xây dựng mô hình cần làm rõ quy mô dữ liệu, đặc điểm caption, độ sạch nhãn và nguy cơ rò rỉ dữ liệu giữa các tập huấn luyện và đánh giá.

Bên cạnh đó, ở báo cáo tuần trước, việc chạy thử mô hình BLIP tiền huấn luyện cho thấy mô hình gốc có thể hoạt động ổn định, nhưng đầu ra vẫn là tiếng Anh và chưa thể dùng trực tiếp cho mục tiêu mô tả ảnh bằng tiếng Việt. Từ đó, bước chuẩn bị dữ liệu tiếng Việt trở thành yêu cầu bắt buộc trước khi finetune.

Vì vậy, trong tuần này, nội dung chính được thực hiện là xây dựng notebook tiền xử lý và chuẩn hóa bộ dữ liệu **UIT-OpenViIC**, đồng thời tiến hành phân tích thống kê, kiểm tra chất lượng dữ liệu, làm sạch dữ liệu và xuất ra các file đầu vào đã chuẩn hóa để phục vụ cho bước huấn luyện mô hình ở giai đoạn tiếp theo.

2. Mục tiêu thực hiện

Nội dung thực hiện trong tuần này tập trung vào bộ dữ liệu **UIT-OpenViIC**, là một trong những bộ dữ liệu tiếng Việt đã được lựa chọn và khảo sát trước đó. Ở báo cáo ngày 14-03, bộ dữ liệu này đã được đánh giá là có quy mô khá tốt cho bài toán image captioning tiếng Việt, với hơn 13 nghìn ảnh và hơn 61 nghìn caption, đồng thời có số lượng caption trên mỗi ảnh tương đối cao và mức độ rò rỉ dữ liệu thấp.

Mục tiêu cụ thể của tuần này gồm bốn phần.

Phần thứ nhất là đọc và khám phá cấu trúc thực tế của các file annotation train, dev, test nhằm đưa dữ liệu về một định dạng thống nhất, trong đó mỗi dòng biểu diễn một cặp ảnh – caption.

Phần thứ hai là chuẩn hóa caption tiếng Việt ở mức cơ bản nhưng cần thiết cho huấn luyện, bao gồm chuẩn hóa Unicode, đưa về chữ thường, loại bỏ khoảng trắng thừa và làm gọn định dạng câu.

Phần thứ ba là phân tích các đặc trưng quan trọng của dữ liệu như quy mô bộ dữ liệu, phân bố độ dài caption, tần suất từ vựng, các trường hợp rỗng, trùng lặp, quá ngắn, quá dài và các khả năng rò rỉ dữ liệu giữa các split.

Phần thứ tư là làm sạch dữ liệu và xuất ra các file CSV, JSONL đã chuẩn hóa để có thể sử dụng trực tiếp cho pipeline finetune mô hình BLIP trong bước tiếp theo. Mục tiêu này bám sát định hướng trong đề cương, nơi giai đoạn 2 của dự án yêu cầu thực hiện thu thập và tiền xử lý dữ liệu trước khi finetune mô hình.

3. Môi trường và thiết lập thực hiện

Trong tuần này, phần tiền xử lý dữ liệu được triển khai dưới dạng một notebook Jupyter. Môi trường sử dụng gồm **Python**, cùng với các thư viện phổ biến cho xử lý dữ liệu và trực quan hóa như **pandas**, **pathlib**, **json**, **re**, **unicodedata**, **matplotlib**, **seaborn** và **Pillow**. Cách triển khai này phù hợp với định hướng công nghệ đã nêu trong đề cương, trong đó Python là ngôn ngữ chính, còn các thư viện xử lý dữ liệu và ảnh được sử dụng để xây dựng pipeline phục vụ huấn luyện mô hình.

Dữ liệu đầu vào gồm ba file annotation tương ứng với ba tập **train**, **dev** và **test**, cùng với thư mục chứa toàn bộ ảnh. Notebook được thiết kế để đọc các file JSON này, suy luận cấu trúc dữ liệu thực tế, sau đó chuẩn hóa toàn bộ dữ liệu về một DataFrame chung gồm các trường chính như **split**, **image_id**, **image_file**, **caption** và **caption_original**. Cách tổ chức này giúp cho dữ liệu dễ phân tích hơn và đồng thời sẵn sàng cho bước huấn luyện sau này.

4. Nội dung thực hiện tiền xử lý và chuẩn hóa dữ liệu

Quá trình thực hiện trong tuần này được triển khai theo một chuỗi các bước tương đối đầy đủ và có tính hệ thống.

Trước hết, em đọc ba file annotation train, dev và test, sau đó kiểm tra nhanh kiểu dữ liệu ở mức top-level, số lượng phần tử và cấu trúc của từng bản ghi. Kết quả cho thấy dữ liệu annotation được tổ chức theo dạng từ điển, trong đó khóa chính là tên file ảnh và mỗi phần tử chứa danh sách caption tương ứng. Từ cấu trúc đó, em xây dựng một hàm suy luận schema để chuyển toàn bộ dữ liệu về cùng một định dạng chuẩn.

Tiếp theo, toàn bộ dữ liệu của ba split được gộp về một DataFrame thống nhất, trong đó mỗi dòng biểu diễn một cặp ảnh – caption. Với cách biểu diễn này, số lượng bản ghi đúng bằng tổng số caption của toàn bộ dataset. Đây là dạng biểu diễn phù hợp cho cả thống kê mô tả lẫn bước xây dựng dataloader cho huấn luyện mô hình image captioning sau này.

Sau đó, em tiến hành chuẩn hóa caption tiếng Việt. Cụ thể, caption được chuẩn hóa Unicode theo chuẩn NFC, loại bỏ xuống dòng, chuyển về chữ thường, rút gọn nhiều khoảng trắng liên tiếp và xử lý lại khoảng trắng trước dấu câu. Việc chuẩn hóa này được thực hiện ở mức vừa phải, không làm mất dấu tiếng Việt và không can thiệp sâu vào ngữ nghĩa của câu. Về mặt bản chất, đây là bước làm sạch ngôn ngữ đầu vào để giảm nhiễu trước khi mô hình học, tương tự như vai trò của text preprocessing trong các bài toán NLP đã được trình bày ở báo cáo nền tảng trước đó.

Sau bước chuẩn hóa caption, em tiếp tục thực hiện các phân tích mô tả chính gồm: thống kê quy mô dataset, kiểm tra chất lượng caption, kiểm tra tính toàn vẹn của file ảnh, phân tích độ dài caption, thống kê từ vựng cơ bản, kiểm tra rò rỉ dữ liệu giữa các split, và cuối cùng là làm sạch dữ liệu theo các tiêu chí tối thiểu để tạo ra tập dữ liệu sẵn sàng cho huấn luyện.

5. Kết quả phân tích và chuẩn hóa dữ liệu

Kết quả thực tế trong notebook cho thấy sau khi chuẩn hóa về một DataFrame thống nhất, bộ dữ liệu có **61.241** dòng dữ liệu tương ứng với **61.241 caption**, trải trên **13.100**

ảnh độc nhất. Xét theo từng split, tập **train** có **9.088 ảnh** và **41.238 caption**, tập **dev** có **2.011 ảnh** và **10.002 caption**, còn tập **test** có **2.001 ảnh** và **10.001 caption**.

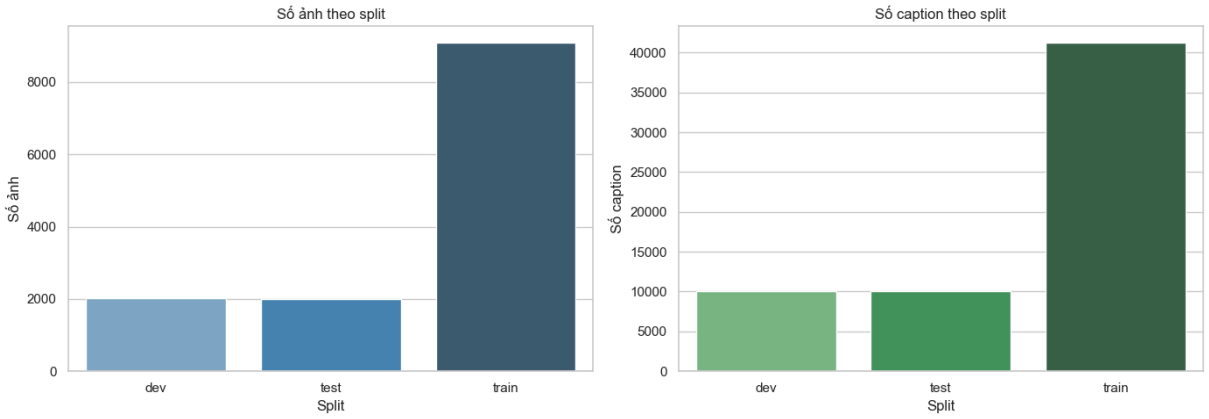

Hình 5.1. Thống kê số lượng ảnh và số lượng caption theo từng tập train, dev và test.

Trung bình toàn bộ dataset có khoảng **4,67 caption trên mỗi ảnh**.

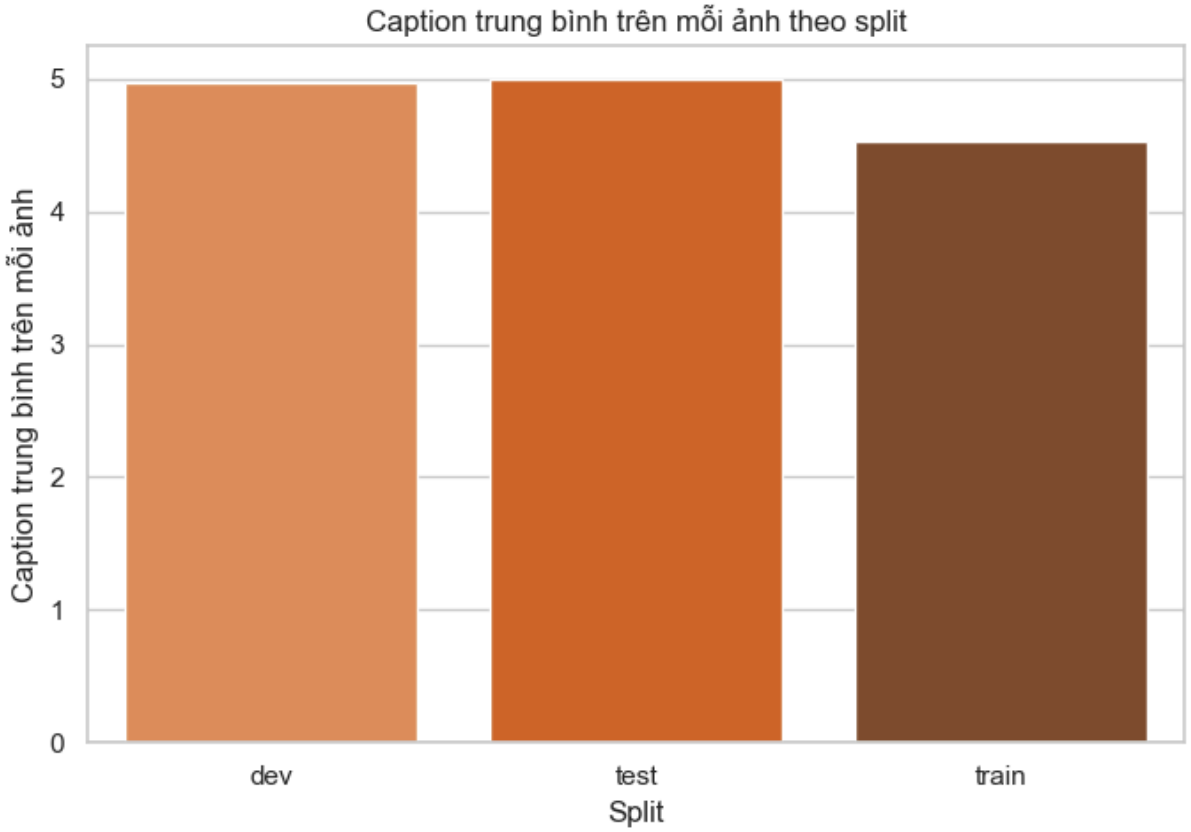

Hình 5.2. Số lượng caption trung bình trên mỗi ảnh theo từng tập dữ liệu.

Các con số này nhất quán với phần khảo sát dataset đã được trình bày ở báo cáo ngày 14-03.

Về mặt chất lượng caption, notebook phát hiện **0 caption null**, **2 caption rỗng**, **4 caption gần như rỗng**, **4 caption quá ngắn**, **493 caption quá dài** theo ngưỡng kiểm tra đang sử dụng, và **10 annotation bị trùng trong cùng một ảnh**. Ngoài ra, nếu tính theo toàn bộ tập dữ liệu, có **369 dòng caption nằm trong nhóm caption trùng toàn cục**. Kết quả này cho thấy dữ liệu nhìn chung tương đối sạch, song vẫn tồn tại một số ngoại lệ cần được loại bỏ hoặc ít nhất phải ghi nhận trước khi bước vào huấn luyện. Phần lớn nhận định này cũng phù hợp với báo cáo khảo sát dataset trước đó, nơi đã nêu rằng UIT-OpenViIC có số lỗi kỹ thuật nhỏ, nhưng vẫn tồn tại caption rỗng, một số caption dài bất thường và annotation trùng trong cùng ảnh.

Về tính toàn vẹn ảnh, kết quả kiểm tra cho thấy toàn bộ **13.100 ảnh** đều tồn tại trong thư mục dữ liệu và **không có ảnh nào bị hỏng**. Đây là một kết quả tích cực vì nếu file ảnh bị thiếu hoặc hỏng thì quá trình huấn luyện có thể bị gián đoạn hoặc gây lỗi ở khâu đọc dữ liệu. Nhận định này cũng thống nhất với báo cáo trước đó, trong đó phần kiểm tra chất lượng dữ liệu đã cho thấy không có ảnh thiếu và không có ảnh hỏng.

Về độ dài caption, tính trên toàn bộ dataset sau chuẩn hóa, độ dài trung bình của caption đạt khoảng **17,61 từ**, trung vị **16 từ**, giá trị nhỏ nhất **0 từ** và lớn nhất **127 từ**. Khi tách theo từng split, tập train có trung bình khoảng **17,30 từ**, tập dev khoảng **18,65 từ**, còn tập test khoảng **17,86 từ**. Nhìn chung, độ dài caption của bộ dữ liệu ở mức vừa phải, đủ để mô tả tương đối chi tiết nội dung ảnh mà chưa quá dài tới mức gây nhiễu lớn cho mô hình. Đồng thời, sự xuất hiện của một số caption rất dài cũng cho thấy vẫn còn tồn tại một vài annotation ngoại lệ cần chú ý trong bước tiền xử lý. Điều này hoàn toàn nhất quán với phần phân tích độ dài caption đã được trình bày trước đó trong báo cáo khảo sát dataset.

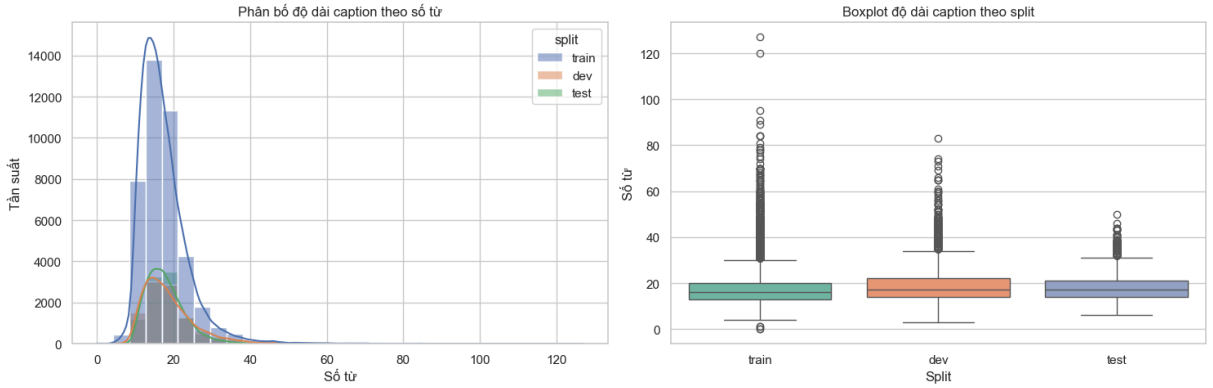

Hình 5.3. Phân bố độ dài caption theo số từ và boxplot độ dài caption trên các tập train, dev, test.

Về mặt từ vựng, notebook thống kê được **880.663 token** sau bước lọc cơ bản và khoảng **4.123 token duy nhất**. Các từ xuất hiện nhiều nhất tiếp tục cho thấy đặc trưng ngôn ngữ rất rõ của bộ dữ liệu, trong đó nổi bật là các từ như **"có"**, **"màu"**, **"người"**, **"nhiều"**, **"hàng"**, **"bên"**, **"xanh"**, **"trắng"**, **"áo"**, **"nhà"**, **"mặc"**, **"trước"**. Từ góc độ nội dung, điều này cho thấy caption của bộ dữ liệu thiên mạnh về mô tả con người, màu sắc, trang phục và quan hệ không gian. Đây cũng là đúng xu hướng đã được rút ra ở báo cáo 14-03, nơi các từ như "màu", "hàng", "bên", "xanh", "trắng", "áo", "nhà", "mặc", "trước" đã được xác định là những từ có tần suất rất cao.

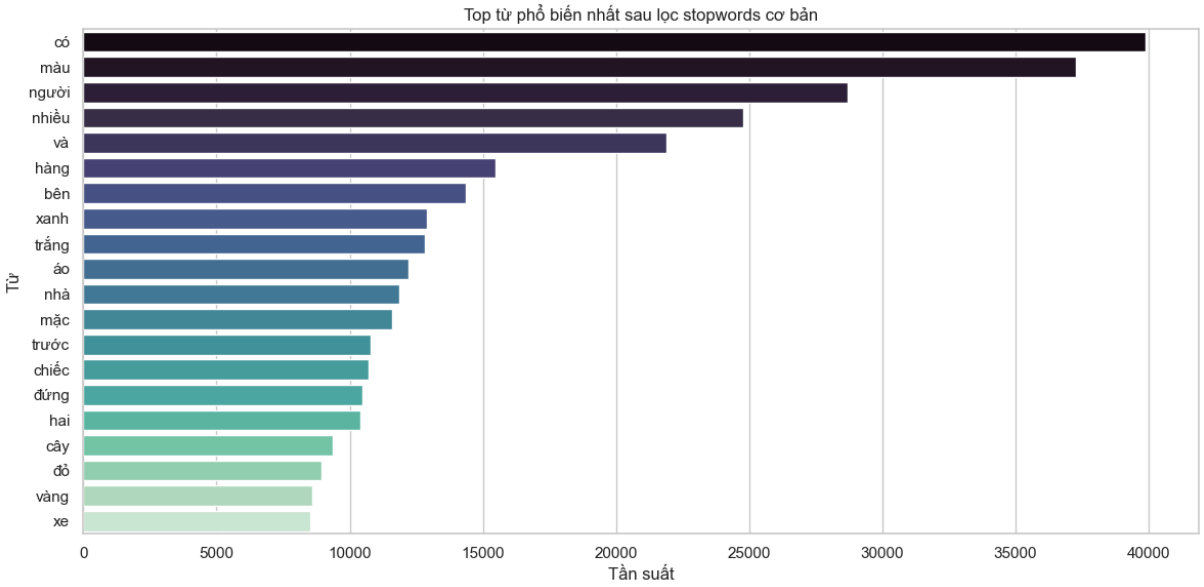

Hình 5.4. Các từ xuất hiện nhiều nhất trong caption sau bước chuẩn hóa và lọc stopwords cơ bản.

Một điểm đáng chú ý trong notebook tuần này là phần kiểm tra giao nhau giữa các split. Ở mức **ảnh**, kết quả cho thấy **không có ảnh nào trùng giữa train, dev và test**, đây là tín hiệu tốt vì nó giúp tránh rò rỉ dữ liệu trực tiếp theo ảnh. Tuy nhiên, ở mức **caption trùng tuyệt đối sau chuẩn hóa**, notebook phát hiện có một số caption chung giữa các cặp split, cụ thể train-dev, train-test và dev-test đều có một số lượng giao nhau nhất định. Kết quả này chặt chẽ hơn so với báo cáo khảo sát trước đó, trong đó mới ghi nhận chắc chắn không có ảnh trùng và có ít nhất một caption test trùng hoàn toàn với train. Như vậy, có thể thấy sau khi chuẩn hóa caption và kiểm tra lại bằng notebook, mức độ giao nhau về văn bản giữa các split cần được quan sát kỹ hơn so với đánh giá ban đầu. Tuy vậy, do overlap theo ảnh vẫn bằng 0, nguy cơ rò rỉ dữ liệu trực tiếp ở mức ảnh vẫn rất thấp.

Sau khi tổng hợp các tiêu chí kiểm tra, em tiến hành làm sạch dữ liệu bằng cách loại bỏ caption null, caption rỗng, ảnh thiếu và ảnh hỏng. Do dữ liệu ảnh hoàn chỉnh và số caption lỗi rất ít, số lượng bản ghi sau làm sạch giảm từ **61.241** xuống còn **61.239**, tức chỉ loại bỏ **2 caption rỗng**. Điều này cho thấy bộ dữ liệu ban đầu đã có chất lượng kỹ thuật khá tốt, và việc làm sạch chủ yếu mang tính chuẩn bị để đảm bảo pipeline huấn luyện ổn định hơn.

Cuối cùng, em xuất các tập dữ liệu đã xử lý ra các file **CSV** và **JSONL** tương ứng cho train, dev, test và toàn bộ dataset. Các file này đóng vai trò là đầu vào trực tiếp cho các bước tiếp theo trong quá trình finetune mô hình BLIP.

6. Nhận xét về bộ dữ liệu sau khi tiền xử lý

Qua quá trình thực hiện notebook và quan sát toàn bộ kết quả phân tích, có thể thấy bộ dữ liệu **UIT-OpenViIC** là một bộ dữ liệu khá phù hợp cho bài toán image captioning tiếng Việt trong phạm vi đề tài.

Ưu điểm đầu tiên là quy mô dữ liệu tương đối tốt, với hơn 13 nghìn ảnh và hơn 61 nghìn caption. Mỗi ảnh đi kèm nhiều caption tham chiếu, giúp mô hình có cơ hội học được nhiều cách diễn đạt ngôn ngữ khác nhau cho cùng một nội dung thị giác. Đặc điểm này cũng đã được ghi nhận từ báo cáo khảo sát dataset trước đó.

Ưu điểm thứ hai là độ sạch dữ liệu ở mức khá cao. Kết quả kiểm tra cho thấy không có ảnh thiếu, không có ảnh hỏng, số caption rỗng rất ít và số annotation lỗi trong cùng ảnh cũng không lớn. Điều này giúp cho bước chuẩn bị dữ liệu không quá phức tạp và thuận lợi cho quá trình huấn luyện sau này. Nhận định này phù hợp với đánh giá tổng quát ở báo cáo 14-03 rằng bộ dữ liệu tương đối sạch và số lỗi kỹ thuật là rất ít.

Ưu điểm thứ ba là về mặt nội dung ngôn ngữ, caption của bộ dữ liệu khá giàu chi tiết, đặc biệt ở các thuộc tính như màu sắc, quần áo, vị trí không gian và bối cảnh xung quanh. Đây là dạng tín hiệu rất có ích đối với bài toán image captioning vì nó giúp mô hình học được mối liên hệ rõ hơn giữa đặc trưng hình ảnh và biểu thức ngôn ngữ. Điều này cũng đồng nhất với nhận định trước đó rằng dữ liệu chứa nhiều tín hiệu ngôn ngữ gắn với thị giác.

Tuy nhiên, notebook tuần này cũng cho thấy một số điểm cần lưu ý. Trước hết, dữ liệu vẫn còn tồn tại một số caption ngoại lệ như caption rỗng, caption quá ngắn và caption quá dài. Dù số lượng không lớn, các trường hợp này vẫn có thể gây ảnh hưởng không mong muốn trong quá trình huấn luyện nếu không được xử lý.

Bên cạnh đó, thống kê từ vựng cho thấy dữ liệu thiên mạnh về mô tả con người, trang phục, màu sắc và các bối cảnh sinh hoạt thường ngày. Đây là ưu điểm nếu mục tiêu

ứng dụng tập trung vào môi trường đời sống thực, nhưng cũng đồng nghĩa với nguy cơ mô hình học thiên lệch về các mẫu mô tả quen thuộc. Điểm này cũng đã từng được nêu trong báo cáo trước: dữ liệu có tính ứng dụng tốt cho cảnh đời sống con người, nhưng chưa thật sự cân bằng giữa các lớp ngữ nghĩa.

Ngoài ra, kết quả kiểm tra overlap sau chuẩn hóa cho thấy cần tiếp tục chú ý đến mức giao nhau của caption giữa các split, dù chưa có sự trùng lặp theo ảnh. Ở giai đoạn hiện tại, đây chưa phải là vấn đề quá nghiêm trọng, nhưng là một chi tiết quan trọng cần được ghi nhận khi bước sang giai đoạn đánh giá mô hình.

7. Kết luận

Trong tuần này, em đã hoàn thành bước **tiền xử lý và chuẩn hóa bộ dữ liệu UIT-OpenViIC** cho bài toán image captioning tiếng Việt. Quá trình thực hiện bao gồm đọc và khám phá cấu trúc annotation, chuẩn hóa dữ liệu về một định dạng thống nhất, làm sạch caption tiếng Việt, phân tích thống kê mô tả, kiểm tra chất lượng dữ liệu, kiểm tra tính toàn vẹn của ảnh, phân tích độ dài caption, phân tích từ vựng, kiểm tra mức độ giao nhau giữa các split và xuất ra các file dữ liệu đã xử lý.

Kết quả thực nghiệm trong notebook cho thấy bộ dữ liệu có quy mô tương đối tốt, chất lượng kỹ thuật khá cao và chỉ cần làm sạch ở mức cơ bản để có thể sử dụng cho bước huấn luyện. Sau khi loại bỏ các bản ghi lỗi tối thiểu, tập dữ liệu sạch còn **61.239** mẫu hợp lệ, sẵn sàng cho quá trình xây dựng pipeline finetune.

Từ kết quả này có thể khẳng định rằng bước chuẩn bị dữ liệu tiếng Việt cho đề tài đã được triển khai đúng hướng và phù hợp với tiến độ đề cương. Đây là tiền đề trực tiếp để chuyển sang bước tiếp theo là thiết kế pipeline huấn luyện và finetune mô hình BLIP trên bộ dữ liệu tiếng Việt, nhằm tiến gần hơn tới mục tiêu xây dựng hệ thống mô tả hình ảnh phục vụ người khiếm thị. Nội dung này cũng nối tiếp trực tiếp kết luận của báo cáo tuần trước, trong đó đã xác định chuẩn bị dữ liệu tiếng Việt là bước tiếp theo cần thực hiện sau khi thử nghiệm BLIP tiền huấn luyện.