

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN I



BÁO CÁO HÀNG TUẦN MÔN
THỰC TẬP CƠ SỞ

Giảng viên hướng dẫn	: TS. Kim Ngọc Bách
Sinh viên thực hiện	: Mã sinh viên
Nguyễn Việt Quang	: B23DCCN691

Hà Nội – 2026

I. Phân tích và lựa chọn mô hình Text-to-Speech tiếng Việt cho hệ thống mô tả hình ảnh

1. Mở đầu

Trong tiến trình hoàn thiện hệ thống mô tả hình ảnh phục vụ người khiếm thị, sau khi đã xây dựng pipeline sinh caption tiếng Việt từ ảnh dựa trên mô hình BLIP fine-tuned với PhoBERT Tokenizer, bước tiếp theo có ý nghĩa quyết định đến tính khả dụng thực tế của ứng dụng là tích hợp mô-đun chuyển đổi văn bản thành giọng nói (Text-to-Speech, TTS). Người dùng khiếm thị không thể đọc nội dung caption được hiển thị trên màn hình, vì vậy việc đọc to nội dung mô tả bằng giọng nói tự nhiên là yêu cầu bắt buộc để hệ thống có thể sử dụng được trong thực tế.

Tuy nhiên, tiếng Việt là một ngôn ngữ có đặc trưng ngữ âm phức tạp với sáu thanh điệu và hệ thống dấu thanh phong phú, khiến việc tổng hợp giọng nói tiếng Việt tự nhiên trở thành một bài toán kỹ thuật không tầm thường. Nhiều mô hình TTS đa ngôn ngữ phổ biến như những mô hình được huấn luyện chủ yếu trên tiếng Anh thường xử lý kém với tiếng Việt do không có cơ chế đặc thù cho hệ thanh điệu của ngôn ngữ này. Do đó, việc khảo sát kỹ lưỡng các mô hình TTS được thiết kế hoặc tối ưu hóa đặc biệt cho tiếng Việt là bước quan trọng trước khi đưa ra quyết định tích hợp.

Trong tuần này, nội dung thực hiện tập trung vào việc nghiên cứu, so sánh và đánh giá ba mô hình TTS tiếng Việt mã nguồn mở nổi bật hiện có, đồng thời đề xuất lựa chọn mô hình phù hợp nhất với yêu cầu của đề tài, bao gồm các tiêu chí về chất lượng giọng đọc, khả năng chạy offline, hiệu năng suy luận trên phần cứng phổ thông và mức độ dễ tích hợp vào pipeline hiện có.

2. Mục tiêu thực hiện

Mục tiêu cụ thể của tuần này bao gồm ba phần chính.

Phần thứ nhất là khảo sát và tổng hợp thông tin về ba mô hình TTS tiếng Việt mã nguồn mở đại diện cho các hướng tiếp cận khác nhau: VieNeu-TTS, viXTTS và VietTTS, bao gồm kiến trúc mô hình, dữ liệu huấn luyện, hiệu năng và các đặc điểm kỹ thuật liên quan.

Phần thứ hai là phân tích từng mô hình dựa trên bộ tiêu chí đánh giá phù hợp với yêu cầu của đề tài, gồm chất lượng âm thanh đầu ra, khả năng hoạt động offline, yêu cầu phần cứng, mức độ hỗ trợ ngôn ngữ tiếng Việt và mức độ thuận tiện trong tích hợp.

Phần thứ ba là đưa ra đề xuất lựa chọn mô hình có căn cứ kỹ thuật rõ ràng, đồng thời xác định hướng tích hợp vào pipeline demo ứng dụng ở giai đoạn tiếp theo.

3. Bối cảnh kỹ thuật và yêu cầu đặt ra

Trước khi phân tích từng mô hình, cần xác định rõ bộ tiêu chí đánh giá xuất phát từ đặc thù của đề tài. Hệ thống hướng tới đối tượng người khiếm thị sử dụng trong môi trường thực tế, vì vậy một số yêu cầu kỹ thuật là không thể thỏa hiệp.

Yêu cầu đầu tiên là khả năng chạy hoàn toàn offline. Người khiếm thị sử dụng ứng dụng trong nhiều môi trường khác nhau, không phải lúc nào cũng có kết nối mạng ổn định. Một mô hình phụ thuộc vào API đám mây sẽ không đáp ứng được yêu cầu này. Yêu cầu thứ hai là chất lượng giọng đọc tự nhiên với tiếng Việt có dấu thanh chuẩn xác. Đây là yêu cầu cốt lõi vì caption sinh ra từ mô hình BLIP là văn bản tiếng Việt đầy đủ dấu, và nếu TTS đọc sai thanh điệu thì thông tin truyền đạt đến người dùng sẽ sai lệch. Yêu cầu thứ ba là hiệu năng chấp nhận được trên phần cứng phổ thông, ưu tiên CPU để không yêu cầu người dùng cuối phải có GPU. Yêu cầu thứ tư là khả năng tích hợp đơn giản với Python, vì toàn bộ pipeline hiện tại được xây dựng bằng Python với các thư viện PyTorch và OpenCV.

4. Khảo sát các mô hình TTS tiếng Việt

4.1. VietTTS

VietTTS là thư viện TTS tiếng Việt mã nguồn mở được phát triển bởi tác giả NTT123 trên GitHub, sử dụng kiến trúc kết hợp giữa acoustic model và vocoder HiFiGAN. Mô hình được huấn luyện trên bộ dữ liệu do công ty InfoRe Technology đóng góp, là tập dữ liệu tiếng Việt đơn giọng đọc được làm sạch và căn chỉnh bằng công cụ Montreal Forced Aligner. Mô hình có bản demo trực tuyến trên Hugging Face Spaces và tài liệu cài đặt cơ bản trên GitHub.

Về ưu điểm, VietTTS được thiết kế thuần túy cho tiếng Việt nên có khả năng xử lý thanh điệu ở mức cơ bản tốt hơn các mô hình đa ngôn ngữ không được tinh chỉnh. Cài đặt tương đối đơn giản thông qua pip và tương thích với Python. Về hạn chế, mô hình này

có lựa chọn giọng nói rất hạn chế, chủ yếu là một giọng đọc đơn. Quan trọng hơn, dự án không còn được cập nhật tích cực trong thời gian gần đây, lần commit gần nhất đã cách khá lâu so với hai mô hình còn lại được khảo sát. Chất lượng âm thanh cũng ở mức trung bình so với các mô hình thế hệ mới hơn sử dụng kiến trúc neural hiện đại hơn. Đây là điểm đáng lo ngại khi triển khai vào một ứng dụng có yêu cầu chất lượng giọng nói tự nhiên để phục vụ người khiếm thị.

4.2. viXTTS

viXTTS là mô hình TTS được fine-tune từ nền tảng XTTS-v2.0.3 của Coqui AI, được phát triển bởi nhóm tác giả capleaf và thynhlp. Mô hình mở rộng tokenizer của XTTS-v2 để hỗ trợ tiếng Việt và được huấn luyện trên bộ dữ liệu viVoice, một tập dữ liệu giọng nói tiếng Việt đa giọng đọc được tổng hợp từ nhiều nguồn. Điểm nổi bật của viXTTS là khả năng nhân bản giọng nói (voice cloning) đa ngôn ngữ với chỉ sáu giây audio mẫu tham chiếu, đồng thời hỗ trợ tổng cộng 18 ngôn ngữ bao gồm tiếng Việt.

Về ưu điểm, viXTTS thừa hưởng kiến trúc XTTS mạnh mẽ với chất lượng âm thanh 24kHz và khả năng sinh giọng nói tương đối tự nhiên. Tính năng voice cloning linh hoạt cho phép tùy chỉnh giọng đọc theo người dùng cụ thể, một tính năng tiềm năng hữu ích cho người khiếm thị muốn nghe giọng quen thuộc. Về hạn chế, có hai vấn đề kỹ thuật quan trọng được ghi nhận qua đánh giá thực nghiệm. Thứ nhất, mô hình hoạt động kém với các câu đầu vào ngắn dưới mười từ trong tiếng Việt, dễ sinh ra âm thanh thừa hoặc không nhất quán ở cuối câu. Đây là hạn chế đáng kể vì caption sinh ra từ mô hình BLIP thường có độ dài vừa phải, hoàn toàn có thể rơi vào vùng dưới mười từ. Thứ hai, hiệu năng suy luận trên CPU là khá chậm do mô hình được thiết kế tối ưu cho GPU, và việc chạy trên CPU không có NVIDIA Container Toolkit sẽ gặp nhiều khó khăn trong thiết lập môi trường. Ngoài ra, mặc dù hỗ trợ tiếng Việt, mô hình đã được chứng minh có WER (Word Error Rate) trong bài toán nhận diện giọng đọc tiếng Việt cao hơn đáng kể so với một số mô hình chuyên biệt hơn trong các đánh giá học thuật gần đây.

4.3. VieNeu-TTS

VieNeu-TTS là mô hình TTS tiếng Việt mã nguồn mở được phát triển bởi tác giả pnnbao97, phát hành trên GitHub với giấy phép Apache 2.0. Mô hình được thiết kế với triết lý on-device, tức ưu tiên khả năng chạy hoàn toàn trên thiết bị người dùng mà không cần kết nối mạng hay máy chủ đám mây. VieNeu-TTS-v2, phiên bản hiện tại, được huấn

luyện trên hơn 10.000 giờ dữ liệu tiếng Việt và tiếng Anh song ngữ, sinh ra âm thanh với tần số lấy mẫu 24kHz. Mô hình cung cấp SDK Python đơn giản với tên gói là vieneu, có thể cài đặt trực tiếp qua pip và chạy được trên cả CPU lẫn GPU thông qua định dạng GGUF và ONNX được tối ưu hóa.

Về ưu điểm, VieNeu-TTS có một số đặc điểm rất phù hợp với yêu cầu đề tài. Đầu tiên là khả năng suy luận thời gian thực trên CPU mà không cần GPU, nhờ mô hình được lượng tử hóa về định dạng GGUF và ONNX. Đây là đặc điểm then chốt để ứng dụng có thể triển khai rộng rãi trên phần cứng phổ thông. Thứ hai là tích hợp Python cực kỳ đơn giản: chỉ cần ba dòng lệnh để khởi tạo, sinh giọng nói và lưu file audio. Thứ ba là mô hình đang được phát triển rất tích cực, với bản release gần nhất vào tháng 4 năm 2026, cho thấy dự án còn đang được duy trì và cải thiện liên tục. Thứ tư là hỗ trợ song ngữ Việt-Anh liền mạch, rất thuận lợi vì caption đôi khi chứa các từ tiếng Anh như tên thương hiệu hoặc thuật ngữ kỹ thuật. Về hạn chế, VieNeu-TTS hiện vẫn ở trạng thái beta, nghĩa là một số tính năng có thể chưa ổn định hoàn toàn. Tuy nhiên, với phiên bản Turbo mode mặc định sử dụng GGUF/ONNX, các tính năng cốt lõi là tổng hợp giọng nói và chạy trên CPU đã hoạt động ổn định qua nhiều lần kiểm thử.

5. So sánh tổng hợp các mô hình

Nhìn tổng quan, ba mô hình đại diện cho ba thế hệ và triết lý phát triển khác nhau. VietTTS thuộc thế hệ cũ hơn với kiến trúc acoustic model truyền thống, chất lượng trung bình và không còn được cập nhật tích cực. viXTTS thuộc thế hệ mới hơn với kiến trúc transformer mạnh mẽ và khả năng đa ngôn ngữ, nhưng gặp hạn chế kỹ thuật nghiêm trọng với câu ngắn tiếng Việt và yêu cầu phần cứng cao. VieNeu-TTS thuộc thế hệ hiện tại với thiết kế tối ưu cho on-device inference, đang được phát triển tích cực và cân bằng tốt giữa chất lượng, hiệu năng và khả năng tích hợp.

Xét riêng theo từng tiêu chí quan trọng với đề tài: về chất lượng giọng tiếng Việt, VieNeu-TTS và viXTTS đều vượt trội so với VietTTS nhờ được huấn luyện trên khối lượng dữ liệu lớn hơn nhiều với kiến trúc neural hiện đại. Về khả năng chạy offline trên CPU, VieNeu-TTS có lợi thế rõ rệt nhờ thiết kế on-device với định dạng GGUF/ONNX, trong khi viXTTS yêu cầu môi trường phức tạp hơn. Về xử lý câu ngắn, VieNeu-TTS không có hạn chế này trong khi viXTTS có vấn đề đã được ghi nhận rõ ràng. Về mức độ đang được duy trì tích cực, VieNeu-TTS dẫn đầu với các bản cập nhật liên tục trong

năm 2026. Về độ đơn giản tích hợp Python, cả ba mô hình đều có thể tích hợp được, nhưng VieNeu-TTS có SDK Python rõ ràng và tài liệu đầy đủ nhất.

6. Đề xuất lựa chọn và kế hoạch tích hợp

Dựa trên phân tích trên, VieNeu-TTS được đề xuất là mô hình TTS sẽ được tích hợp vào hệ thống demo của đề tài. Lý do cốt lõi của lựa chọn này là sự phù hợp toàn diện với bộ yêu cầu đặc thù của ứng dụng hỗ trợ người khiếm thị: chạy offline, không cần GPU, tích hợp Python đơn giản, chất lượng giọng tiếng Việt tốt và không có hạn chế kỹ thuật nghiêm trọng với độ dài câu như viXTTS.

Về kế hoạch tích hợp, pipeline dự kiến sẽ hoạt động theo luồng sau: khi người dùng kích hoạt chụp ảnh, hệ thống gọi mô hình BLIP để sinh caption tiếng Việt, sau đó đoạn văn bản caption này được truyền vào VieNeu-TTS để tổng hợp giọng nói, và file audio đầu ra được phát qua loa ngay lập tức. Toàn bộ quy trình này diễn ra hoàn toàn offline trên thiết bị. Về hiệu năng, với chế độ Turbo mode mặc định sử dụng GGUF/ONNX, thời gian tổng hợp giọng nói dự kiến đủ nhanh để phản hồi trong vòng vài giây sau khi caption được sinh ra, phù hợp với yêu cầu trải nghiệm người dùng của ứng dụng demo.

7. Nhận xét và đánh giá

Quá trình khảo sát mô hình TTS trong tuần này đã cung cấp một bức tranh tổng quan rõ ràng về hiện trạng của lĩnh vực TTS tiếng Việt mã nguồn mở. Đáng chú ý là sự trưởng thành nhanh chóng của hệ sinh thái này trong hai năm gần đây: trong khi VietTTS đại diện cho thế hệ đầu tiên với chất lượng còn hạn chế, VieNeu-TTS cho thấy đã có những bước tiến đáng kể về cả chất lượng âm thanh lẫn hiệu năng suy luận on-device.

Một điểm đáng phản biện là việc lựa chọn VieNeu-TTS dù mô hình vẫn còn ở trạng thái beta. Tuy nhiên, đây là đánh đổi có chủ ý: với phạm vi đề tài là xây dựng một demo hệ thống mô tả ảnh cho người khiếm thị, yêu cầu về tính ổn định hoàn hảo ở mức sản phẩm thương mại là chưa cần thiết. Điều quan trọng hơn là mô hình phải đáp ứng được các yêu cầu kỹ thuật cốt lõi, và VieNeu-TTS ở chế độ Turbo/Standard đã thể hiện sự ổn định đủ để sử dụng trong môi trường demo. Ngoài ra, việc mô hình đang được phát triển tích cực còn là một lợi thế, vì các lỗi nếu có sẽ được vá nhanh hơn so với dự án đã ngừng cập nhật.

Một quan sát khác là trong bài toán hỗ trợ người khiếm thị, chất lượng giọng đọc và tính tự nhiên của âm thanh ảnh hưởng trực tiếp đến trải nghiệm người dùng nhiều hơn bất kỳ chỉ số kỹ thuật nào khác. Vì vậy, bước tiếp theo sau khi tích hợp kỹ thuật là cần tiến hành thử nghiệm nghe thực tế để đánh giá chủ quan chất lượng giọng đọc trên các caption thực tế được sinh ra bởi mô hình BLIP.

8. Kết luận

Trong tuần này, em đã thực hiện khảo sát, phân tích và so sánh ba mô hình TTS tiếng Việt mã nguồn mở gồm VietTTS, viXTTS và VieNeu-TTS theo bộ tiêu chí phù hợp với yêu cầu đặc thù của đề tài hỗ trợ người khiếm thị. Kết quả phân tích cho thấy VieNeu-TTS là lựa chọn phù hợp nhất nhờ khả năng chạy hoàn toàn offline trên CPU, tích hợp Python đơn giản qua SDK vieneu, chất lượng giọng tiếng Việt tốt, không có hạn chế kỹ thuật với câu ngắn, và đang được phát triển tích cực với bản cập nhật mới nhất vào tháng 4 năm 2026.

Trong giai đoạn tiếp theo, em sẽ tiến hành tích hợp VieNeu-TTS vào pipeline demo của ứng dụng, kết nối trực tiếp với đầu ra caption của mô hình BLIP để hoàn thiện luồng xử lý từ đầu đến cuối: từ ảnh đầu vào, qua sinh caption tiếng Việt, đến phát giọng nói mô tả hình ảnh cho người khiếm thị. Đây là bước cuối cùng để hoàn thiện sản phẩm demo theo đúng định hướng ban đầu của đề cương.