HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN I

BÁO CÁO HẰNG TUẦN MÔN
THỰC TẬP CƠ SỞ

Giảng viên hướng dẫn : TS. Kim Ngọc Bách
Sinh viên thực hiện : Mã sinh viên
Nguyễn Việt Quang : B23DCCN691

Hà Nội - 2026

I. Finetuning mô hình VLM

1. VLM là gì và vì sao cần finetuning

Vision-Language Model là mô hình học đồng thời từ hai loại dữ liệu: ảnh và văn bản. Khác với mô hình chỉ xử lý ảnh hoặc chỉ xử lý ngôn ngữ, VLM phải học được ba thứ cùng lúc: hiểu nội dung thị giác, hiểu nội dung ngôn ngữ, và quan trọng nhất là liên kết hai phía đó với nhau. Khi thấy một bức ảnh và một câu mô tả, mô hình không chỉ nhận ra vật thể trong ảnh mà còn phải biết từ nào trong câu gắn với phần nào của ảnh, câu đó có mô tả đúng nội dung ảnh hay không, hoặc từ ảnh có thể sinh ra câu phù hợp hay không.

Một mô hình như BLIP thường đã được pretrain trên lượng dữ liệu rất lớn. Nhờ pretraining, mô hình có tri thức chung về thế giới thị giác và ngôn ngữ. Tuy nhiên, tri thức đó chỉ là tri thức tổng quát. Khi đem mô hình vào một bài toán cụ thể như captioning trong y khoa, hỏi đáp trên ảnh sản phẩm, hay truy hồi ảnh-văn bản trong một miền chuyên biệt, mô hình cần được điều chỉnh thêm để thích nghi. Quá trình điều chỉnh đó là finetuning.

Vì vậy, về bản chất, finetuning không phải là dạy mô hình từ đầu, mà là làm cho mô hình đã có tri thức chung trở nên phù hợp hơn với nhiệm vụ và miền dữ liệu cụ thể.

2. Bản chất của finetuning trong VLM

Finetuning là quá trình cập nhật tham số của mô hình pretrained bằng một tập dữ liệu mục tiêu nhỏ hơn nhưng có mục đích rõ hơn. Nếu pretraining nhằm học năng lực tổng quát, thì finetuning nhằm tối ưu hóa năng lực đó cho một mục tiêu xác định.

Trong VLM, finetuning có hai tầng ý nghĩa. Thứ nhất là thích nghi với task, tức làm cho mô hình giải tốt một dạng bài toán cụ thể như mô tả ảnh, VQA hay retrieval. Thứ hai là thích nghi với domain, tức làm cho mô hình quen với một loại dữ liệu đặc thù như ảnh y tế, ảnh tài liệu, ảnh thương mại điện tử hoặc ảnh vệ tinh. Hai chuyện này thường đi cùng nhau: task thay đổi thì cách mô hình dùng liên kết ảnh-văn bản cũng thay đổi, còn domain thay đổi thì các đặc trưng thị giác và ngôn ngữ cũng thay đổi.

Điểm quan trọng nhất là trong finetuning VLM, đối tượng cần được giữ gìn và điều chỉnh cẩn thận không chỉ là phần hiểu ảnh hay hiểu text riêng lẻ, mà là mối quan hệ giữa chúng. Nếu liên kết đa phương thức bị lệch, mô hình có thể vẫn đọc được văn bản và vẫn nhận ra vật thể, nhưng không còn ghép đúng văn bản với hình ảnh.

3. Kiến trúc khái niệm của một VLM như BLIP

Để hiểu finetuning, trước hết cần hiểu một VLM như BLIP gồm những thành phần nào.

3.1. Vision encoder

Đây là khối nhận ảnh làm đầu vào và biến ảnh thành một dãy biểu diễn số, thường gọi là visual embeddings hoặc visual tokens. Có thể hình dung nó là bộ phận trích xuất đặc trưng thị giác: vật thể nào xuất hiện, hình dạng ra sao, màu sắc thế nào, bố cục không gian thế nào. Vision encoder không tạo ra câu chữ; nó tạo ra một biểu diễn trừu tượng của ảnh mà các khối phía sau có thể sử dụng.

3.2. Text encoder hoặc text decoder

Phần xử lý ngôn ngữ nhận chuỗi văn bản rồi biến chúng thành các biểu diễn ngữ nghĩa. Tùy nhiệm vụ mà khối này có vai trò hơi khác nhau. Nếu mục tiêu là hiểu một câu mô tả hoặc một câu hỏi, nó đóng vai trò encoder. Nếu mục tiêu là sinh ra caption hay câu trả lời, nó đóng vai trò decoder hoặc một bộ sinh chuỗi tự hồi quy. Nói đơn giản, đây là phần giúp mô hình hiểu và sinh ngôn ngữ.

3.3. Multimodal fusion

Đây là phần trung tâm của VLM. Nó kết hợp thông tin từ visual tokens và text tokens để tạo ra biểu diễn chung. Chính tại đây mô hình học rằng một cụm từ nào đó trong câu tương ứng với một vùng hay một đối tượng nào đó trong ảnh, hoặc toàn bộ câu có ăn khớp với toàn bộ ảnh hay không. Nếu vision encoder và text encoder là hai nguồn tri thức riêng, thì fusion là nơi tạo ra tri thức đa phương thức thực sự.

Về mặt khái niệm, khi finetuning VLM, phần nhạy cảm nhất thường là phần fusion, vì đây là nơi tri thức ảnh và văn bản được buộc lại với nhau.

4. Mục tiêu học trong finetuning VLM

Finetuning không thể tách rời khỏi learning objective, tức mô hình được yêu cầu học điều gì. Trong VLM, các objective phản ánh những kiểu liên kết khác nhau giữa ảnh và văn bản.

4.1. Contrastive learning

Ở đây mô hình học rằng ảnh đúng phải gần với văn bản đúng trong không gian biểu diễn, còn ảnh và văn bản không liên quan phải cách xa nhau. Mục tiêu này tạo ra sự căn chỉnh ở mức toàn cục giữa hai modality. Nó đặc biệt quan trọng cho các bài toán truy hồi ảnh-văn bản. Nếu coi embedding là cách đặt ảnh và văn bản vào cùng một bản đồ, contrastive learning làm cho những cặp có cùng nghĩa nằm gần nhau trên bản đồ đó.

4.2. Image-text matching

Khác với contrastive learning vốn đo sự gần xa ở mức embedding toàn cục, image-text matching hỏi trực tiếp: cặp ảnh-văn bản này có thật sự khớp nhau hay không. Đây là một bài toán phân loại nhị phân. Nó buộc mô hình xem xét quan hệ ở mức ngữ nghĩa cụ thể hơn. Một câu có thể nói gần đúng về chủ đề ảnh nhưng sai chi tiết; matching giúp mô hình học những khác biệt kiểu đó.

4.3. Conditional language modeling

Nếu nhiệm vụ là captioning hoặc sinh câu trả lời, mô hình phải học sinh chuỗi ngôn ngữ có điều kiện theo ảnh hoặc theo cặp ảnh-câu hỏi. Khi đó objective là dự đoán token tiếp theo dựa trên ngữ cảnh ngôn ngữ và tín hiệu thị giác. Đây là cơ chế cốt lõi của các nhiệm vụ sinh văn bản từ ảnh.

Ba nhóm objective này đại diện cho ba kiểu năng lực: căn chỉnh toàn cục, kiểm tra khớp ngữ nghĩa, và sinh ngôn ngữ có điều kiện. Một mô hình như BLIP thường mạnh vì nó không chỉ học một kiểu duy nhất mà kết hợp nhiều objective.

5. Dữ liệu finetuning và ý nghĩa của alignment

Dữ liệu trong finetuning VLM không chỉ là dữ liệu lớn hay nhỏ, mà quan trọng hơn là dữ liệu có đúng quan hệ ảnh-văn bản mà task yêu cầu hay không. Với mô hình ảnh-ngôn ngữ, chất lượng của mối ghép giữa ảnh và text thường quan trọng hơn nhiều so với việc chỉ tăng số lượng mẫu.

Nếu bài toán là captioning, dữ liệu phải thể hiện được mối quan hệ ảnh-câu mô tả. Nếu bài toán là VQA, dữ liệu phải phản ánh quan hệ giữa ảnh, câu hỏi và câu trả lời. Nếu bài toán là retrieval, dữ liệu phải đảm bảo rằng mỗi cặp ảnh-văn bản đúng thật sự mang cùng nội dung ngữ nghĩa.

Khái niệm quan trọng nhất ở đây là alignment dữ liệu. Alignment nghĩa là text phải phản ánh đúng thông tin trong ảnh theo cách mà task cần. Một caption sai, thiếu, quá chung chung hoặc bị nhiễu sẽ làm hỏng quá trình học căn chỉnh đa phương thức. Trong VLM, nhiễu dữ liệu không chỉ làm giảm hiệu quả, mà còn dễ phá hỏng liên kết giữa hai modality.

6. Finetuning thực sự thay đổi cái gì trong mô hình

Về mặt khái niệm, finetuning có thể tác động lên ba lớp tri thức.

Thứ nhất là tri thức thị giác: mô hình học biểu diễn hình ảnh phù hợp hơn với miền mới. Ví dụ, cùng là một vùng ảnh, trong dữ liệu web nó có thể chỉ là một vật thể bình thường, nhưng trong ảnh y khoa nó mang ý nghĩa bệnh lý rất đặc thù.

Thứ hai là tri thức ngôn ngữ: mô hình phải quen với từ vựng, cách diễn đạt, cấu trúc câu chuyên ngành hoặc phong cách mô tả riêng của dữ liệu mục tiêu.

Thứ ba, và là quan trọng nhất, là tri thức liên kết chéo giữa ảnh và văn bản. Đây là việc mô hình học rằng trong domain mới, những kiểu mô tả nào gắn với những đặc trưng thị giác nào. Khi domain thay đổi, bản thân ánh xạ giữa đặc trưng ảnh và biểu thức ngôn ngữ cũng đổi theo.

Do đó, finetuning VLM không chỉ là sửa phần thị giác hay phần ngôn ngữ riêng lẻ, mà là tái điều chỉnh toàn bộ cơ chế gắn kết giữa hai phần đó.

7. Các chiến lược finetuning

Không phải lúc nào cũng nên cập nhật toàn bộ mô hình. Về mặt khái niệm, lựa chọn chiến lược finetuning phụ thuộc vào ba yếu tố: lượng dữ liệu, tài nguyên tính toán và mức độ khác biệt giữa domain mới với domain cũ.

7.1. Full finetuning

Toàn bộ tham số của mô hình được cập nhật. Cách này cho phép mô hình thích nghi mạnh nhất vì mọi thành phần đều có thể thay đổi. Tuy nhiên nó tốn tài nguyên nhất và dễ overfit nếu dữ liệu mục tiêu ít. Khái niệm cốt lõi ở đây là tính linh hoạt cao nhưng đánh đổi bằng chi phí cao và rủi ro cao.

7.2. Partial finetuning

Chỉ một phần mô hình được cập nhật, ví dụ giữ nguyên vision encoder và chỉ điều chỉnh fusion cùng đầu ra. Cách này dựa trên giả định rằng một phần tri thức pretrained vẫn còn hữu ích và không cần thay đổi nhiều. Khái niệm quan trọng ở đây là bảo toàn tri thức nền, chỉ thích nghi những phần gần task nhất.

7.3. Parameter-efficient finetuning

Mô hình gốc phần lớn bị đóng băng, chỉ thêm vào các tham số nhỏ có thể học. Ý tưởng nền tảng là tri thức pretrained quá giá trị để sửa trực tiếp toàn bộ, nên ta tạo ra một lớp điều chỉnh nhẹ giúp mô hình thích nghi mà không cần cập nhật mọi thứ. Về bản chất, đây là cách tách tri thức nền và tri thức thích nghi task thành hai phần khác nhau.

Ba chiến lược này phản ánh ba triết lý khác nhau: sửa toàn bộ, sửa chọn lọc, hoặc giữ nguyên gần như toàn bộ và chỉ thêm cơ chế thích nghi nhỏ.

8. Domain shift và domain adaptation

Một mô hình BLIP pretrained thường học từ dữ liệu web phổ quát. Khi chuyển sang một domain khác, ví dụ tài liệu, y khoa hay ảnh công nghiệp, phân phối dữ liệu thay đổi. Sự thay đổi này gọi là domain shift. Nó có thể xuất hiện ở hình ảnh, ở ngôn ngữ, hoặc ở cách hai phía liên kết với nhau.

Ví dụ, cùng một từ mô tả có thể mang nghĩa khác trong domain mới; hoặc những chi tiết hình ảnh từng không quan trọng trong dữ liệu web lại trở thành tín hiệu chính trong dữ liệu chuyên ngành. Finetuning chính là cơ chế domain adaptation, tức điều chỉnh mô hình để sống được trong phân phối mới đó.

Khái niệm cần nắm là: càng khác domain pretrain, mô hình càng cần được điều chỉnh mạnh hơn; và phần liên kết ảnh-văn bản thường bị ảnh hưởng nhiều nhất.

9. Overfitting trong finetuning VLM

Overfitting xảy ra khi mô hình học quá sát vào tập finetune mà mất khả năng tổng quát hóa. Trong VLM, nguy cơ này cao vì mô hình rất lớn, còn dữ liệu finetuning thường nhỏ. Ngoài ra, nếu dữ liệu đa phương thức có cấu trúc hẹp hoặc lặp mẫu, mô hình rất dễ học thuộc các mẫu liên kết thay vì học quy luật chung.

Về mặt khái niệm, overfitting trong VLM không chỉ là nhớ hình hay nhớ câu, mà còn là nhớ sai mối quan hệ giữa hình và câu. Khi đó mô hình có thể trả lời tốt trên các mẫu quen thuộc nhưng thất bại khi ảnh hoặc cách diễn đạt thay đổi một chút.
Do đó, một phần quan trọng của finetuning là kiểm soát mức độ thích nghi: đủ để phù hợp với task mới nhưng không phá mất năng lực tổng quát đã có từ pretraining.

10. Đầu ra của finetuning là gì

Khi finetuning thành công, mô hình không đơn giản là có loss thấp hơn. Thay đổi sâu hơn là biểu diễn đa phương thức của nó trở nên phù hợp hơn với task và domain mới. Nghĩa là:

- ảnh được mã hóa theo cách hữu ích hơn cho bài toán đang xét
- văn bản được hiểu theo ngữ cảnh chuyên biệt hơn
- liên kết giữa đặc trưng ảnh và ngôn ngữ trở nên chính xác hơn
- cơ chế sinh hoặc phán đoán đầu ra trở nên phù hợp hơn với mục tiêu

Nói cách khác, sản phẩm thực sự của finetuning là một mô hình có cùng nền tảng kiến trúc nhưng có không gian biểu diễn và cơ chế liên kết đã được tái định hình cho một bối cảnh sử dụng cụ thể.

II. Nghiên cứu tìm hiểu 1 số bộ dataset cho bài toán Image Captioning trong tiếng Việt

1. Mở đầu

Trong bài toán image captioning, chất lượng bộ dữ liệu quyết định trực tiếp đến khả năng học biểu diễn thị giác và sinh ngôn ngữ của mô hình. Vì vậy, trước khi xây dựng mô hình, cần tiến hành phân tích dữ liệu nhằm làm rõ quy mô tập dữ liệu, đặc điểm ngôn ngữ của caption, mức độ đa dạng ngữ nghĩa, độ sạch của nhãn và nguy cơ rò rỉ dữ liệu giữa các tập huấn luyện và đánh giá.
Bộ dữ liệu được khảo sát là UIT-OpenViIC và UITVIC. Nội dung phân tích tập trung vào các tiêu chí cơ bản nhưng quan trọng đối với một bộ dữ liệu image captioning, bao gồm: quy mô dữ liệu, độ dài caption, đặc trưng từ vựng, mức độ trùng lặp, chất lượng dữ liệu, phân bố chủ đề và sự chồng lấn giữa các tập train, dev, test.

2. Tổng quan về quy mô bộ dữ liệu

Kết quả thống kê cho thấy bộ dữ liệu gồm 13.100 ảnh độc nhất và 61.241 caption. Trung bình mỗi ảnh có 4,67 caption. Đây là một đặc điểm tích cực vì với bài toán image captioning, việc mỗi ảnh có nhiều câu mô tả giúp phản ánh đa dạng cách diễn đạt ngôn ngữ cho cùng một nội dung thị giác.

Xét theo từng tập dữ liệu:

- Tập train gồm 9.088 ảnh và 41.238 caption, trung bình 4,54 caption mỗi ảnh.
- Tập dev gồm 2.011 ảnh và 10.002 caption, trung bình 4,97 caption mỗi ảnh.
- Tập test gồm 2.001 ảnh và 10.001 caption, trung bình 5,00 caption mỗi ảnh.

Có thể nhận thấy số lượng caption trên mỗi ảnh tương đối ổn định giữa các tập. Điều này cho thấy cách xây dựng bộ dữ liệu có tính nhất quán, thuận lợi cho quá trình huấn luyện và đánh giá mô hình.

3. Đặc điểm độ dài caption và từ vựng

Phân tích độ dài caption theo số từ cho thấy caption trong bộ dữ liệu có độ dài trung bình tương đối đồng đều giữa các tập:

- Train: trung bình 17,30 từ, trung vị 16 từ, lớn nhất 127 từ.
- Dev: trung bình 18,65 từ, trung vị 17 từ, lớn nhất 83 từ.
- Test: trung bình 17,86 từ, trung vị 17 từ, lớn nhất 50 từ.

Nhìn chung, độ dài caption của bộ dữ liệu ở mức vừa phải, đủ để mô tả tương đối chi tiết nội dung ảnh, nhưng không quá dài đến mức gây nhiễu lớn cho mô hình. Tuy nhiên, tập train xuất hiện caption dài bất thường tới 127 từ; đây là dấu hiệu cho thấy có thể tồn tại một số annotation ngoại lệ cần được xem xét thêm khi tiền xử lý.

Về mặt ngôn ngữ, các caption của bộ dữ liệu mang phong cách mô tả giàu chi tiết và thường nhấn mạnh vào màu sắc, trang phục, vị trí không gian và bối cảnh xung quanh. Đây là một đặc trưng đáng chú ý vì mô hình được huấn luyện trên bộ dữ liệu này có xu hướng học mạnh các tín hiệu thị giác liên quan đến thuộc tính bề mặt, đặc biệt là màu sắc và vật thể dễ nhận biết.

4. Phân tích từ vựng và tần suất xuất hiện từ

Sau khi loại bỏ stopwords, các từ xuất hiện nhiều nhất trong bộ dữ liệu bao gồm các từ như: "màu", "hàng", "bên", "xanh", "trắng", "áo", "nhà", "mặc", "trước". Kết quả này phản ánh rõ đặc điểm của tập caption:

Thứ nhất, caption thường mô tả mạnh về màu sắc và trang phục. Các từ như "màu", "xanh", "trắng", "áo" xuất hiện với tần suất rất cao cho thấy nhiều ảnh tập trung vào con người hoặc vật thể có thể mô tả trực tiếp bằng màu sắc.

Thứ hai, các từ chỉ quan hệ không gian và bối cảnh như "bên", "trước", "nhà" cũng xuất hiện dày đặc. Điều này cho thấy caption không chỉ gọi tên đối tượng mà còn mô tả vị trí hoặc môi trường xuất hiện của đối tượng.

Từ góc độ mô hình hóa, đây là một ưu điểm vì dữ liệu chứa nhiều tín hiệu ngôn ngữ gắn với thị giác. Tuy nhiên, nó cũng hàm ý rằng mô hình có thể dễ thiên về học các mẫu mô tả quen thuộc, ví dụ mô tả quần áo, màu sắc hoặc bố cục cảnh, hơn là học các quan hệ ngữ nghĩa sâu hơn.

5. Mức độ trùng lặp của caption

Một trong những tiêu chí quan trọng khi đánh giá chất lượng bộ dữ liệu image captioning là mức độ trùng lặp của annotation. Kết quả cho thấy:

- Tổng số caption: 61.241
- Số caption độc nhất: 61.025
- Số caption trùng lặp: 216
- Tỉ lệ trùng lặp: 0,35%

Tỉ lệ này là rất thấp, cho thấy bộ dữ liệu có độ đa dạng ngôn ngữ tương đối tốt. Một số caption lặp lại nhiều lần thường thuộc kiểu mô tả khái quát, ví dụ các cảnh chợ, cửa hàng, siêu thị hoặc người ngồi gần hồ nước. Đây là các ngữ cảnh phổ biến nên việc xuất hiện một số câu tương tự nhau là điều có thể chấp nhận được.

Ngoài ra, notebook còn phát hiện 10 annotation bị lặp lại trong cùng một ảnh. Dạng lỗi này tuy không lớn về số lượng nhưng vẫn cần lưu ý vì nó làm giảm giá trị của việc có nhiều caption tham chiếu cho một ảnh.

Nhìn chung, xét trên toàn cục, mức độ trùng lặp của bộ dữ liệu là thấp và chưa tạo thành vấn đề nghiêm trọng.

6. Kiểm tra chất lượng dữ liệu

6.1. Caption rỗng

Kết quả phát hiện 2 caption rỗng hoặc không chứa chữ. Cả hai đều nằm trong tập train. Đây là lỗi annotation ở mức nhỏ, song vẫn cần được loại bỏ trước khi huấn luyện vì caption rỗng có thể gây lỗi trong các bước tokenize, build vocabulary hoặc batch training.

6.2. Tính toàn vẹn của ảnh

Kiểm tra sự tồn tại và khả năng mở ảnh trên đĩa cho thấy:

- Không có ảnh nào bị thiếu.
- Không có ảnh nào bị hỏng.

Đây là một kết quả rất tích cực, cho thấy bộ dữ liệu được tổ chức tốt ở mức file vật lý. Trong thực hành, đây là điều quan trọng vì lỗi file ảnh thường làm gián đoạn quá trình huấn luyện hoặc đánh giá.

6.3. Nhận xét chung về độ sạch dữ liệu

Tổng hợp các kiểm tra trên cho thấy bộ dữ liệu có chất lượng kỹ thuật cao. Các lỗi phát hiện được chỉ ở mức rất nhỏ, chủ yếu là caption rỗng và một số annotation trùng trong cùng ảnh. Do đó, với một bước tiền xử lý đơn giản, bộ dữ liệu có thể được sử dụng tương đối an toàn cho huấn luyện mô hình.

7. Phân bố đối tượng và chủ đề chính

Notebook đã nhóm caption theo các chủ đề lớn dựa trên keyword. Kết quả cho thấy:

- Người và con người: 28.416 caption, chiếm 46,40%
- Bối cảnh ngoài trời: 23.038 caption, chiếm 37,62%
- Đồ vật và nội thất: 14.379 caption, chiếm 23,48%
- Phương tiện: 9.951 caption, chiếm 16,25%
- Động vật: 843 caption, chiếm 1,38%

Từ kết quả này có thể rút ra một số nhận xét quan trọng.

Thứ nhất, bộ dữ liệu thiên mạnh về ảnh chứa con người. Đây là đặc điểm phổ biến ở nhiều bộ dữ liệu captioning thực tế, nhưng đồng thời cũng khiến mô hình dễ học thiên lệch về các mẫu mô tả người, trang phục và hoạt động đời thường.

Thứ hai, bối cảnh ngoài trời chiếm tỉ lệ cao, cho thấy nhiều ảnh phản ánh cảnh sinh hoạt, đường phố, cây cối hoặc không gian công cộng. Điều này làm giàu khả năng học bối cảnh của mô hình.

Thứ ba, nhóm động vật chiếm tỉ lệ rất thấp. Vì vậy, nếu sử dụng bộ dữ liệu này để huấn luyện mô hình captioning tổng quát, mô hình có thể hoạt động kém hơn trên các ảnh động vật do dữ liệu đại diện chưa đủ mạnh.

Như vậy, xét về độ đa dạng chủ đề, bộ dữ liệu có tính ứng dụng tốt cho các cảnh đời sống và sinh hoạt con người, nhưng chưa thật sự cân bằng giữa các lớp ngữ nghĩa.

8. Kiểm tra rò rỉ dữ liệu giữa các tập

Vấn đề overlap giữa train, dev và test là một tiêu chí đặc biệt quan trọng trong đánh giá mô hình. Nếu cùng một ảnh hoặc cùng một caption xuất hiện ở nhiều tập, kết quả đánh giá có thể bị lạc quan giả tạo.

Kết quả kiểm tra cho thấy:

- Không có ảnh trùng giữa train và dev.
- Không có ảnh trùng giữa train và test.
- Không có ảnh trùng giữa dev và test.

Đây là dấu hiệu rất tốt, cho thấy việc chia tập theo ảnh được thực hiện chính xác.

Ở mức caption chính xác tuyệt đối, chỉ có 1 caption của tập test trùng hoàn toàn với một caption trong tập train. Câu đó là: "hai người phụ nữ đang lựa đồ trong một cửa hàng quần áo".

Trường hợp này không nhất thiết là lỗi nghiêm trọng, bởi trong bài toán captioning, có những cấu trúc mô tả ngắn và khuôn mẫu có thể xuất hiện lặp lại ở các ảnh khác nhau. Tuy nhiên, nó vẫn là một điểm cần ghi nhận khi phân tích dữ liệu.

Tổng thể, nguy cơ rò rỉ dữ liệu của bộ dữ liệu UIT-OpenViIC là rất thấp.

9. Đánh giá tổng quát về bộ dữ liệu

Từ các kết quả đã phân tích, có thể đưa ra đánh giá tổng quát như sau.

Bộ dữ liệu UIT-OpenViIC có quy mô khá tốt cho bài toán image captioning tiếng Việt, với hơn 13 nghìn ảnh và hơn 61 nghìn caption. Số lượng caption trên mỗi ảnh tương đối cao, tạo điều kiện thuận lợi cho huấn luyện và đánh giá bằng nhiều câu tham chiếu. Về mặt ngôn ngữ, caption có độ dài trung bình hợp lý và thể hiện xu hướng mô tả khá chi tiết. Từ vựng phản ánh rõ các thuộc tính thị giác như màu sắc, quần áo, vị trí và bối cảnh. Điều này giúp mô hình học được các đặc trưng trực quan quan trọng.

Về chất lượng dữ liệu, bộ dữ liệu tương đối sạch. Số lỗi kỹ thuật rất ít, không có ảnh thiếu hoặc ảnh hỏng. Tỉ lệ caption trùng lặp thấp và hầu như không có rò rỉ dữ liệu giữa các tập.

Tuy nhiên, bộ dữ liệu cũng có một số hạn chế. Phân bố chủ đề chưa thật sự cân bằng, trong đó nhóm liên quan đến con người chiếm ưu thế rõ rệt, còn động vật xuất hiện rất ít. Ngoài ra, vẫn tồn tại một số caption rỗng, caption quá dài bất thường và một số annotation trùng trong cùng một ảnh.

TÀI LIỆU THAM KHẢO

[1] Nguyễn Minh Hải. (26, 08. 2025).Fine-tuning là gì? Ứng dụng của mô hình trong thực tiễn đời sống [Online].Từ: https://vnptai.io/vi/blog/detail/fine-tuning-la-gi

[2] kaggle.com. (2025). Open-viic [Online]. Từ: https://www.kaggle.com/datasets/patonn/open-viic