

**HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN I**



**BÁO CÁO HÀNG TUẦN MÔN
THỰC TẬP CƠ SỞ**

Giảng viên hướng dẫn	: TS. Kim Ngọc Bách
Sinh viên thực hiện	: Mã sinh viên
Nguyễn Việt Quang	: B23DCCN691

Hà Nội – 2026

I. Cải tiến Pipeline Huấn luyện, Nâng cấp Mô hình lên v3 và Thử nghiệm Demo Sinh Caption Theo Thời Gian Thực

1. Mở đầu

Tiếp nối kết quả của vòng huấn luyện trước với bộ chỉ số BLEU-4 đạt 6.18, ROUGE-L đạt 34.21 và METEOR đạt 34.62 (mô hình v2), tuần này tập trung vào việc cải tiến toàn diện pipeline huấn luyện nhằm khắc phục các hạn chế còn tồn đọng và nâng cao chất lượng mô hình. Các hạn chế cần giải quyết bao gồm: chiến lược đóng băng vision encoder hoàn toàn khiến mô hình không thể tinh chỉnh thêm đặc trưng thị giác theo ngữ cảnh tiếng Việt; chưa có cơ chế tăng cường dữ liệu để cải thiện tính tổng quát hóa; hàm loss chuẩn không có label smoothing nên mô hình có xu hướng quá tự tin vào dự đoán; và chiến lược lấy mẫu dữ liệu train theo mode flat dẫn đến thiên lệch caption trong mỗi epoch.

Bên cạnh đó, song song với huấn luyện, tuần này cũng hoàn thiện notebook thử nghiệm demo (experiment.ipynb) để chạy pipeline sinh caption theo thời gian thực qua webcam, sử dụng mô hình v3 vừa được huấn luyện. Đây là bước đầu tiên hướng tới mục tiêu xây dựng ứng dụng demo hoàn chỉnh phục vụ người khiếm thị theo đúng định hướng đề tài.

2. Mục tiêu thực hiện

Mục tiêu cụ thể của tuần này bao gồm bốn phần chính.

Phần thứ nhất là cải tiến chiến lược freeze/unfreeze vision encoder: thay vì đóng băng hoàn toàn như trong v2, cho phép fine-tune có chọn lọc hai lớp cuối của vision encoder với learning rate rất nhỏ để mô hình có thể điều chỉnh đặc trưng thị giác cho phù hợp với ngữ cảnh dữ liệu tiếng Việt.

Phần thứ hai là bổ sung data augmentation cho tập train, áp dụng random horizontal flip và color jitter để tăng tính đa dạng của dữ liệu đầu vào, giảm hiện tượng mô hình học thuộc cấu trúc ảnh cụ thể.

Phần thứ ba là tích hợp label smoothing vào hàm loss và chuyển sang chế độ grouped sampling cho tập train, trong đó mỗi ảnh chỉ lấy ngẫu nhiên một caption trong mỗi epoch thay vì sử dụng toàn bộ caption, giúp mô hình học phân phối ngôn ngữ đa dạng hơn.

Phần thứ tư là hoàn thiện notebook thử nghiệm demo với mô hình v3, kiểm chứng khả năng sinh caption tiếng Việt theo thời gian thực qua webcam trên môi trường máy cá nhân.

3. Môi trường và thiết lập thực hiện

Quá trình huấn luyện được thực hiện trên nền tảng Kaggle Notebook với GPU NVIDIA Tesla T4 (16GB VRAM), môi trường Python 3.12 với PyTorch, Transformers và thư viện evaluate của Hugging Face. Dữ liệu đầu vào là bộ dữ liệu UIT-OpenViIC đã được resize về 384x384 và làm sạch từ các tuần trước, lưu trữ dưới dạng Kaggle Dataset. Mô hình nền tảng vẫn là Salesforce/blip-image-captioning-base với PhoBERT Tokenizer (vinai/phobert-base) đã được cấu hình từ vòng huấn luyện trước. Quá trình thử nghiệm demo được thực hiện trên máy cá nhân với GPU NVIDIA GeForce GTX 1650 4GB, hệ điều hành Windows 11, Python 3.11.9 với môi trường ảo .venv.

4. Nội dung thực hiện chi tiết

4.1. Cải tiến Dataset: Grouped Sampling và Data Augmentation

Một trong những thay đổi quan trọng nhất trong vòng huấn luyện này là cải tiến lớp UITViICDataset để hỗ trợ hai chế độ lấy mẫu. Chế độ flat giữ nguyên như cũ, tức là mỗi dòng trong CSV tương ứng với một mẫu dữ liệu riêng biệt. Chế độ grouped mới được bổ sung sử dụng pandas groupby để gom toàn bộ caption của cùng một ảnh lại, sau đó trong mỗi lần đọc sẽ chọn ngẫu nhiên một caption từ danh sách đó. Tập train được cấu hình theo chế độ grouped, trong khi tập dev và test vẫn sử dụng chế độ flat để đảm bảo tính nhất quán trong đánh giá. Kết quả là tập train từ 41.238 mẫu thu gọn xuống còn 9.088 mẫu theo số lượng ảnh độc nhất, nhưng mỗi epoch mô hình sẽ tiếp xúc với một caption khác nhau cho cùng một ảnh, buộc mô hình học phân phối ngôn ngữ đa dạng thay vì học thuộc từng câu cụ thể.

Song song với đó, một pipeline augmentation được áp dụng cho tập train gồm random horizontal flip với xác suất 0.5 và color jitter điều chỉnh nhẹ về độ sáng, tương phản, độ bão hòa màu và sắc tố. Mức độ augmentation được giữ vừa phải để không làm sai lệch nội dung ngữ nghĩa của ảnh, vì caption mô tả màu sắc và bố cục không gian rất cụ thể trong bộ dữ liệu UIT-OpenViIC.

4.2. Chiến lược Partial Unfreeze Vision Encoder

Khác với vòng huấn luyện v2 đóng băng hoàn toàn vision encoder, trong v3 hai lớp cuối cùng của khối `vision_model.encoder.layers` được mở khóa để cập nhật trọng số với learning rate rất nhỏ là $1e-6$, trong khi text decoder được huấn luyện với learning rate $3e-5$. Lý do lựa chọn chỉ mở hai lớp cuối thay vì toàn bộ vision encoder là để tận dụng kiến trúc phân cấp của ViT: các lớp đầu học đặc trưng cấp thấp như cạnh và kết cấu vốn đã ổn định, trong khi các lớp cuối chịu trách nhiệm học đặc trưng ngữ nghĩa cao cấp hơn có thể cần điều chỉnh để phù hợp với phân phối ảnh đời sống Việt Nam trong UIT-OpenViLC. Optimizer được cấu hình với hai nhóm tham số tách biệt nhau, mỗi nhóm có learning rate riêng, cho phép điều khiển tốc độ học độc lập giữa hai phần.

Thống kê sau khi áp dụng chiến lược này cho thấy tổng số tham số mô hình là 249.715.457, trong đó số tham số được huấn luyện là 177.800.705, chiếm 71.2%. Cụ thể, 14.175.744 tham số thuộc hai lớp vision encoder được mở khóa và 163.624.961 tham số thuộc text decoder. So với v2 chỉ huấn luyện khoảng 62% tham số, v3 huấn luyện nhiều hơn 9.2 điểm phần trăm, chủ yếu đến từ phần vision được mở ra thêm.

4.3. Label Smoothing và điều chỉnh siêu tham số

Hàm loss trong v3 được thay thế bằng `CrossEntropyLoss` tùy chỉnh với `label_smoothing=0.1`, tức là phân phối nhãn thật được làm mượt bằng cách phân phối 10% xác suất đều ra toàn bộ vocabulary. Về mặt kỹ thuật, label smoothing có tác dụng điều chuẩn (regularization) tương tự dropout nhưng hoạt động ở không gian nhãn: nó ngăn mô hình học cực đoan theo hướng dự đoán một từ với xác suất gần 1.0, buộc mô hình phải duy trì phân phối xác suất lan rộng hơn trên các từ lân cận có nghĩa tương đồng. Điều này đặc biệt có lợi cho bài toán image captioning vì có nhiều cách diễn đạt hợp lệ cho cùng một nội dung ảnh.

Các siêu tham số khác cũng được điều chỉnh: `MAX_LENGTH` tăng từ 50 lên 64 token để xử lý được các caption dài hơn trong dữ liệu, `EPOCHS` tăng lên 15 để cho mô hình đủ thời gian hội tụ, `PATIENCE` tăng lên 4 để tránh dừng sớm quá mức, và scheduler chuyển sang cosine với 10% warmup steps để có lịch điều chỉnh learning rate mượt mà hơn.

4.4. Kết quả quá trình huấn luyện

Mô hình được huấn luyện đủ 15 epoch mà không kích hoạt early stopping, cho thấy validation loss vẫn tiếp tục cải thiện ở từng epoch mặc dù mức cải thiện giảm dần theo thời gian. Bảng dưới đây tóm tắt diễn biến loss qua một số epoch đại diện:

Epoch	Train Loss	Val Loss	Gap
1	9.1899	6.9674	+2.2225
3	5.4127	5.0949	+0.3178
6	4.3776	4.3771	+0.0005
7	4.2296	4.2925	-0.0628
10	4.0079	4.1427	-0.1349
13	3.9188	4.0982	-0.1794
15	3.9085	4.0939	-0.1854

Bảng 4.1. Diễn biến Train Loss và Val Loss theo epoch

Một đặc điểm đáng chú ý là gap giữa train loss và val loss chuyển từ dương sang âm từ epoch 7, tức là val loss thấp hơn train loss. Hiện tượng này phản ánh tác động của label smoothing: hàm loss được tính trên train set bị làm mượt bởi label smoothing nên thường cao hơn một chút so với tính trên val set không có smoothing. Điều này không phải là dấu hiệu overfitting mà là hệ quả tự nhiên của kỹ thuật regularization đang được áp dụng. Mô hình checkpoint tốt nhất được lưu tại epoch 15 với val loss đạt 4.0939.

4.5. Đánh giá trên tập test và so sánh với v2

Sau khi tải lại checkpoint tốt nhất, pipeline sinh caption được chạy trên toàn bộ 2.001 ảnh của tập test với beam search num_beams=5, no_repeat_ngram_size=3 và repetition_penalty=1.5. Việc tăng num_beams từ 4 lên 5 so với v2 giúp beam search có thêm một hướng tìm kiếm, cải thiện chất lượng câu sinh ra. Mỗi ảnh chỉ được sinh một caption, và caption đó được so sánh với toàn bộ 5 caption tham chiếu tương ứng trong tập test. Kết quả định lượng được tóm tắt trong bảng dưới đây:

Bảng 5.2. So sánh chỉ số đánh giá giữa v2 và v3 trên tập test

Chỉ số	v2 (PhoBERT)	v3 (cải tiến)	Cải thiện
BLEU-1	—	75.80	+75.80
BLEU-2	—	46.19	+46.19
BLEU-3	—	26.42	+26.42
BLEU-4	6.18	33.61	+27.43
ROUGE-L	34.21	53.33	+19.12
METEOR	34.62	40.11	+5.49

Kết quả cho thấy cải thiện rất đáng kể trên tất cả các chỉ số. BLEU-4 tăng từ 6.18 lên 33.61, tức tăng hơn 27 điểm tuyệt đối. ROUGE-L tăng từ 34.21 lên 53.33, tăng gần 20 điểm. METEOR tăng từ 34.62 lên 40.11, tăng khoảng 5.5 điểm. Đặc biệt, BLEU-1 đạt 75.80 và BLEU-2 đạt 46.19 cho thấy mô hình đã học được từ vựng tiếng Việt tốt và có khả năng sinh các cụm từ 2-gram khớp với câu tham chiếu ở mức cao.

Xét các caption mẫu, mô hình đã sinh được những mô tả có chất lượng khá tốt. Ví dụ, với ảnh 00000006091.jpg, mô hình sinh "một tòa nhà màu vàng có nhiều cây xanh" trong khi caption tham chiếu là "một ngôi nhà màu vàng có các sợi dây leo màu xanh quấn xung quanh": các yếu tố chính gồm tòa nhà, màu vàng và cây xanh đều được nhận diện đúng. Với ảnh 00000006092.jpg, mô hình sinh "một người đàn ông mặc áo màu trắng đang đứng trước một tòa nhà", khớp chính xác với màu áo trắng trong caption tham chiếu. Với ảnh 00000006098.jpg về hộp đựng thức ăn trên đĩa trắng, mô hình mô tả đúng cả vật thể lẫn màu sắc. Những kết quả này cho thấy mô hình đã học được khả năng nhận diện và mô tả các đối tượng phổ biến trong dữ liệu UIT-OpenViC ở mức độ tốt.

4.6. Thử nghiệm Demo Sinh Caption theo Thời Gian Thực

Song song với quá trình huấn luyện trên Kaggle, notebook experiment.ipynb được hoàn thiện để thử nghiệm mô hình v3 (saved_models_v3) trên máy cá nhân. Pipeline demo hoạt động theo cơ chế sau: mô hình BLIP được nạp từ thư mục saved_models_v3 lên thiết bị tính toán khả dụng, sau đó vòng lặp chính liên tục đọc khung hình từ webcam

và hiển thị lên cửa sổ. Khi người dùng nhấn phím cách, khung hình hiện tại được chuyển sang không gian màu RGB và đưa qua hàm `predict_caption()` để sinh caption tiếng Việt. Caption sinh ra sau đó được hiển thị trực tiếp lên khung hình thông qua hàm `put_viet_text()`, sử dụng Pillow với font Arial hỗ trợ Unicode để đảm bảo hiển thị đúng dấu thanh tiếng Việt. Người dùng nhấn phím q để thoát.

Thử nghiệm cho thấy pipeline chạy ổn định trên CPU của máy cá nhân với GTX 1650. Mỗi lần sinh caption mất khoảng 1 đến 2 giây trên GPU tích hợp, là mức phản hồi chấp nhận được cho một ứng dụng demo. Caption sinh ra có dấu thanh tiếng Việt đầy đủ và có ngữ nghĩa tương đối phù hợp với nội dung ảnh chụp từ webcam. Đây là lần đầu tiên toàn bộ luồng hoạt động từ đầu đến cuối được kiểm chứng trên môi trường thiết bị thực, không phải trên Kaggle cloud.

5. Nhận xét và đánh giá

Vòng huấn luyện v3 trong tuần này đã đạt được bước tiến vượt bậc so với v2, với BLEU-4 tăng hơn 4 lần từ 6.18 lên 33.61. Phần lớn sự cải thiện này xuất phát từ hai yếu tố chính. Thứ nhất là việc chuyển sang grouped sampling đã giải quyết được vấn đề thiên lệch dữ liệu: khi tập train ở chế độ flat có 41.238 mẫu với nhiều caption lặp lại cho cùng một ảnh, mô hình có xu hướng học thuộc phân phối caption thay vì học hiểu nội dung ảnh thực sự. Grouped sampling buộc mô hình phải generalize tốt hơn vì nó thấy một cách diễn đạt khác nhau cho cùng ảnh ở mỗi epoch. Thứ hai là partial unfreeze vision encoder cho phép mô hình tinh chỉnh thêm đặc trưng thị giác cấp cao, quan trọng trong việc căn chỉnh biểu diễn ảnh với ngôn ngữ tiếng Việt có đặc thù về màu sắc và bối cảnh sinh hoạt đời thường.

Tuy nhiên, một điểm đáng lưu ý là val loss cuối cùng đạt 4.09 vẫn còn tương đối cao về mặt tuyệt đối, cho thấy mô hình vẫn còn dư địa cải thiện. Quan sát các caption mẫu cho thấy một số trường hợp mô hình vẫn mô tả chưa đủ chi tiết hoặc nhầm lẫn đối tượng khi ảnh có bố cục phức tạp. Điều này nhất quán với thực tế là text decoder của BLIP phải học lại hoàn toàn từ đầu với vocabulary PhoBERT khoảng 64.000 token, và 9.088 ảnh của tập train (sau grouped sampling) vẫn là một lượng dữ liệu khiêm tốn cho bài toán học ngôn ngữ từ ảnh với vocabulary lớn như vậy.

Về gap train-val âm từ epoch 7 trở đi, đây là hệ quả tự nhiên của label smoothing chứ không phải dấu hiệu đáng lo ngại. Khi label smoothing làm tăng giá trị loss trên train

set nhưng không áp dụng lên val set, gap sẽ tự nhiên trở nên âm khi mô hình đã học đủ tốt. Thực tế val loss vẫn giảm đều qua 15 epoch xác nhận mô hình đang học tốt và không bị overfitting thực sự.

6. Kết luận

Trong tuần này, em đã hoàn thành cải tiến toàn diện pipeline huấn luyện với các kỹ thuật grouped sampling, data augmentation, partial unfreeze vision encoder và label smoothing, đồng thời huấn luyện thành công mô hình v3 trong 15 epoch trên Kaggle. Kết quả đánh giá trên tập test 2.001 ảnh cho thấy cải thiện vượt bậc: BLEU-4 đạt 33.61, ROUGE-L đạt 53.33 và METEOR đạt 40.11, tăng lần lượt 27.43, 19.12 và 5.49 điểm so với mô hình v2. Bên cạnh đó, thử nghiệm demo trên máy cá nhân qua webcam đã xác nhận toàn bộ pipeline từ ảnh đầu vào đến caption tiếng Việt hiển thị trên màn hình hoạt động ổn định trong môi trường thực.

Trong giai đoạn tiếp theo, em sẽ tập trung vào hai hướng song song: tích hợp mô-đun Text-to-Speech VieNeu-TTS vào pipeline demo để hoàn thiện luồng đọc caption bằng giọng nói cho người khiếm thị, và tiến hành đánh giá thêm về chất lượng caption qua thử nghiệm thực tế với ảnh từ môi trường đời sống hằng ngày nhằm chuẩn bị cho báo cáo tổng kết đề tài.