HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN I

BÁO CÁO HẰNG TUẦN MÔN
THỰC TẬP CƠ SỞ

Giảng viên hướng dẫn : TS. Kim Ngọc Bách
Sinh viên thực hiện : Mã sinh viên
Nguyễn Việt Quang : B23DCCN691

Hà Nội - 2026

I. Nghiên cứu, tìm hiểu mô hình BLIP, BLIP-2 cho bài toán image captioning

1. Mở đầu

Image captioning là bài toán sinh mô tả ngôn ngữ tự nhiên từ ảnh. Bản chất của bài toán này không chỉ là nhận diện vật thể, mà là biến thông tin thị giác thành một câu mô tả mạch lạc, đúng ngữ cảnh và đủ giàu ngữ nghĩa. Vì vậy, một mô hình captioning tốt phải xử lý được ba lớp khó khăn cùng lúc: hiểu nội dung ảnh, căn chỉnh thị giác-ngôn ngữ, và sinh văn bản tự nhiên.

Trong vài năm gần đây, các mô hình vision-language pretraining đã đẩy mạnh chất lượng image captioning nhờ học từ tập dữ liệu ảnh-văn bản quy mô lớn. Trong số đó, BLIP và BLIP-2 là hai cột mốc rất đáng chú ý. BLIP giải quyết đồng thời hai vấn đề: kiến trúc mô hình cần đủ linh hoạt cho cả hiểu và sinh, và dữ liệu web thì rất nhiều nhưng nhiễu. BLIP-2 đi xa hơn: thay vì huấn luyện end-to-end rất đắt đỏ, mô hình tận dụng image encoder và large language model đã huấn luyện sẵn rồi chỉ học một cầu nối nhẹ hơn giữa hai miền.

Xét riêng cho image captioning, BLIP đáng chú ý vì nó học trực tiếp khả năng sinh chú thích từ ảnh trong một khung huấn luyện thống nhất; còn BLIP-2 đáng chú ý vì nó cho thấy captioning có thể mạnh lên đáng kể khi ghép được tri thức của mô hình ảnh mạnh và năng lực sinh ngôn ngữ của LLM.

2. Mô hình BLIP

2.1. Bối cảnh ra đời và bài toán mà BLIP muốn giải quyết

Bài báo BLIP chỉ ra hai hạn chế lớn của các hướng trước đó.

Thứ nhất là hạn chế từ phía mô hình. Nhiều mô hình trước BLIP hoặc mạnh ở các tác vụ understanding như retrieval, VQA; hoặc mạnh ở generation như captioning, nhưng không thật sự linh hoạt cho cả hai. Kiến trúc encoder-based thường giỏi hiểu nhưng không thuận cho sinh chuỗi; ngược lại encoder-decoder thuận cho sinh văn bản nhưng không tối ưu cho các bài toán ghép cặp ảnh-văn bản.

Thứ hai là hạn chế từ phía dữ liệu. Nhiều mô hình thị giác-ngôn ngữ dựa rất nhiều vào dữ liệu web gồm ảnh và alt-text, nhưng alt-text thường nhiễu, không mô tả đúng nội dung ảnh. BLIP xem đây không phải lỗi nhỏ, mà là một nguồn giám sát chưa tối ưu.

Vì vậy, đóng góp của BLIP không chỉ ở kiến trúc mà còn ở cách "làm sạch và làm giàu" dữ liệu.

2.2. Ý tưởng cốt lõi của BLIP

BLIP gồm hai trụ cột.

Trụ cột thứ nhất là **Multimodal Mixture of Encoder-Decoder (MED)**, tức một mô hình thống nhất nhưng có thể hoạt động theo ba chế độ khác nhau: unimodal encoder, image-grounded text encoder, và image-grounded text decoder. Nhờ đó, cùng một họ tham số có thể phục vụ cả hiểu lẫn sinh.

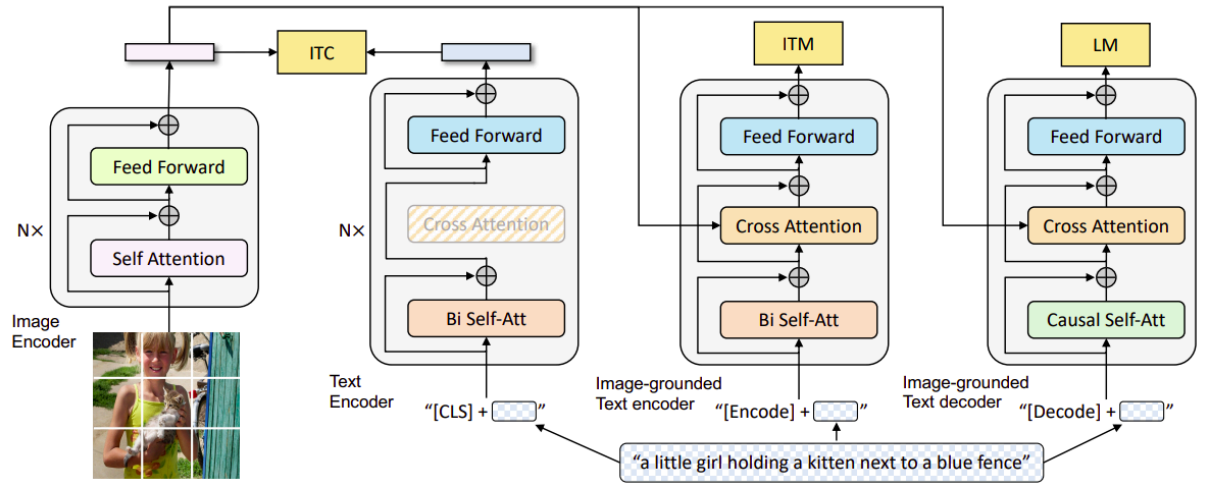

Trụ cột thứ hai là **CapFilt (Captioning and Filtering)**. Thay vì tin hoàn toàn vào alt-text gốc từ web, BLIP dùng một captioner để sinh caption tổng hợp cho ảnh, rồi dùng một filter để loại caption nhiễu, áp dụng cho cả caption gốc lẫn caption sinh ra.

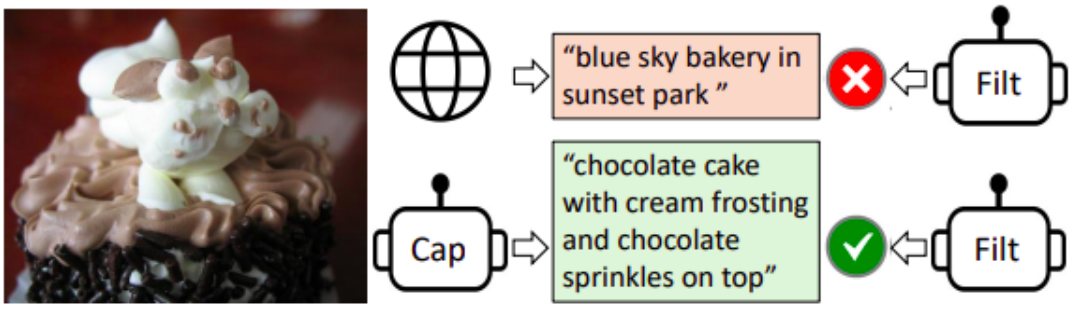

2.3. Kiến trúc MED và cơ chế hoạt động

BLIP dùng ViT làm image encoder. Ảnh được chia thành patch, mã hóa thành chuỗi embedding, kèm token **[CLS]** để biểu diễn toàn cục. Phần text backbone khởi tạo từ BERTbase.

Điểm tinh tế nằm ở ba chế độ vận hành:

Unimodal encoder: ảnh và văn bản được mã hóa riêng. Đây là chế độ dùng cho contrastive learning, nhằm kéo gần biểu diễn ảnh-văn bản đúng cặp và đẩy xa cặp sai.

Image-grounded text encoder: văn bản đi qua text encoder nhưng được bổ sung cross-attention với đặc trưng ảnh. Chế độ này học biểu diễn hợp nhất ảnh-văn bản để làm các bài toán matching.

Image-grounded text decoder: thay bi-directional self-attention bằng causal self-attention, biến mô hình thành bộ giải mã sinh chuỗi có điều kiện theo ảnh. Đây là thành phần trực tiếp phục vụ image captioning.

Tư tưởng ở đây rất rõ: captioning cần mô hình không chỉ "biết ảnh chứa gì", mà còn phải "nói ra" được điều đó theo kiểu autoregressive. BLIP làm điều này bằng cách xây sẵn nhánh decoder thị giác-ngôn ngữ trong cùng hệ mô hình.

2.4. Các mục tiêu huấn luyện của BLIP

BLIP tối ưu đồng thời ba loss:

Image-Text Contrastive Loss (ITC): căn chỉnh không gian biểu diễn ảnh và văn bản. Loss này làm mô hình học sự tương ứng tổng quát giữa hai miền, rất hữu ích cho retrieval và tạo nền cho hiểu ảnh-văn bản.

Image-Text Matching Loss (ITM): phân loại cặp ảnh-văn bản là khớp hay không khớp. Loss này nhấn mạnh căn chỉnh fine-grained, tức mức chi tiết hơn contrastive learning. BLIP còn dùng hard negative mining để chọn âm bản khó.

Language Modeling Loss (LM): huấn luyện decoder sinh caption cho ảnh theo kiểu tự hồi quy. Đây là loss trực tiếp liên quan đến image captioning. Bài báo nhấn mạnh rằng so với masked language modeling, LM phù hợp hơn để mô hình thật sự học cách chuyển thông tin hình ảnh thành câu mô tả mạch lạc.

Nhìn theo góc độ captioning, có thể xem ITC và ITM là hai tầng "hiểu", còn LM là tầng "diễn đạt". BLIP mạnh ở captioning vì nó không coi captioning như phần phụ sau hiểu ảnh, mà huấn luyện thẳng khả năng sinh mô tả trong pretraining.

2.5. CapFilt: đóng góp dữ liệu rất quan trọng của BLIP

CapFilt chính là điểm làm BLIP khác biệt.

Quy trình như sau:

- lấy một mô hình MED đã pretrain,
- fine-tune thành **captioner** trên COCO để sinh caption cho ảnh web,

- fine-tune thành **filter** để chấm xem caption có khớp ảnh không,
- lọc cả web text gốc lẫn caption tổng hợp,
- ghép dữ liệu đã lọc với dữ liệu gán nhãn chất lượng cao để pretrain một mô hình mới.

Điểm mạnh của CapFilt là không chỉ loại nhiễu, mà còn tạo ra mô tả mới giàu ngữ nghĩa hơn alt-text gốc.

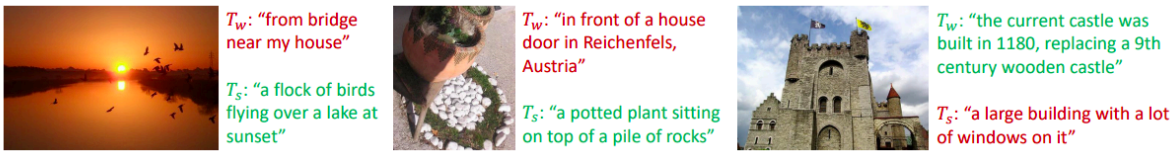

nhiều web text ban đầu mang tính cá nhân, địa danh, hoặc không mô tả nội dung ảnh; trong khi synthetic text mô tả sát hình ảnh hơn.

2.6. Thiết lập tiền huấn luyện của BLIP

BLIP dùng ViT-B/16 hoặc ViT-L/16 làm vision backbone, text transformer khởi tạo từ BERTbase. Dữ liệu pretrain mặc định gồm khoảng 14M ảnh từ COCO, Visual Genome, Conceptual Captions, Conceptual 12M và SBU; sau đó bài báo còn mở rộng với LAION thành khoảng 129M ảnh. Ảnh pretrain ở 224×224, fine-tune ở 384×384.

2.7. Kết quả của BLIP cho image captioning

Pre-train dataset	Bootstrap C	Bootstrap F	Vision backbone	Retrieval-FT (COCO) TR@1	Retrieval-FT (COCO) IR@1	Retrieval-ZS (Flickr) TR@1	Retrieval-ZS (Flickr) IR@1	Caption-FT (COCO) B@4	Caption-FT (COCO) CIDEr	Caption-ZS (NoCaps) CIDEr	Caption-ZS (NoCaps) SPICE
COCO+VG +CC+SBU (14M imgs)	✗	✗	ViT-B/16	78.4	60.7	93.9	82.1	38.0	127.8	102.2	13.9
	✗	✓$_B$		79.1	61.5	94.1	82.8	38.1	128.2	102.7	14.0
	✓$_B$	✗		79.7	62.0	94.4	83.6	38.4	128.9	103.4	14.2
	✓$_B$	✓$_B$		80.6	63.1	94.8	84.9	38.6	129.7	105.1	14.4
COCO+VG +CC+SBU +LAION (129M imgs)	✗	✗	ViT-B/16	79.6	62.0	94.3	83.6	38.8	130.1	105.4	14.2
	✓$_B$	✓$_B$		81.9	64.3	96.0	85.0	39.4	131.4	106.3	14.3
	✓$_L$	✓$_L$		81.2	64.1	96.0	85.5	39.7	133.3	109.6	14.7
	✗	✗	ViT-L/16	80.6	64.1	95.1	85.5	40.3	135.5	112.5	14.7
	✓$_L$	✓$_L$		82.4	65.1	96.7	86.7	40.4	136.7	113.2	14.8

BLIP cho thấy khi thêm captioner và filter, các chỉ số captioning đều tăng. Trên COCO caption fine-tuning, CIDEr tăng từ 127.8 lên 129.7 với tập 14M; trong zero-shot NoCaps, CIDEr tăng từ 102.2 lên 105.1, SPICE từ 13.9 lên 14.4. Khi mở rộng dữ liệu và backbone, kết quả còn cao hơn.

Method	Pre-train #Images	NoCaps validation in-domain C	in-domain S	near-domain C	near-domain S	out-domain C	out-domain S	overall C	overall S	COCO Caption Karpathy test B@4	COCO Caption Karpathy test C
Enc-Dec (Changpinyo et al., 2021)	15M	92.6	12.5	88.3	12.1	94.5	11.9	90.2	12.1	-	110.9
VinVL† (Zhang et al., 2021)	5.7M	103.1	14.2	96.1	13.8	88.3	12.1	95.5	13.5	38.2	129.3
$\text{LEMON}_{\text{base}}$† (Hu et al., 2021)	12M	104.5	14.6	100.7	14.0	96.7	12.4	100.4	13.8	-	-
$\text{LEMON}_{\text{base}}$† (Hu et al., 2021)	200M	107.7	14.7	106.2	14.3	107.9	13.1	106.8	14.1	**40.3**	**133.3**
BLIP	14M	111.3	15.1	104.5	14.4	102.4	13.7	105.1	14.4	38.6	129.7
BLIP	129M	109.1	14.8	105.8	14.4	105.7	13.7	106.3	14.3	39.4	131.4
$\text{BLIP}_{\text{CapFilt-L}}$	129M	**111.8**	**14.9**	**108.6**	**14.8**	**111.5**	**14.2**	**109.6**	**14.7**	39.7	**133.3**
$\text{LEMON}_{\text{large}}$† (Hu et al., 2021)	200M	116.9	15.8	113.3	15.1	111.3	14.0	113.4	15.0	40.6	135.7
$\text{SimVLM}_{\text{huge}}$ (Wang et al., 2021)	1.8B	113.7	-	110.9	-	115.2	-	112.2	-	40.6	143.3
$\text{BLIP}_{\text{ViT-L}}$	129M	114.9	15.2	112.1	14.9	115.3	14.4	113.2	14.8	40.4	136.7

BLIP đạt kết quả rất mạnh trên NoCaps và COCO Caption. Biến thể BLIPViT-L với 129M ảnh đạt CIDEr 136.7 trên COCO Karpathy test và 113.2 CIDEr / 14.8 SPICE trên NoCaps overall. So với nhiều mô hình cùng thời, đây là kết quả rất cạnh tranh, đặc biệt khi mô hình không cần object detector nặng như một số hướng trước.

2.8. Nhận xét riêng cho bài toán image captioning

Đối với image captioning, BLIP mạnh ở ba điểm.

Một là mô hình có nhánh decoder thật sự được huấn luyện để sinh mô tả, nên không phải "ghép tạm" từ backbone understanding.

Hai là mô hình được học từ dữ liệu đã được làm sạch và làm giàu bằng CapFilt, nên tín hiệu giám sát cho captioning tốt hơn alt-text web thô.

Ba là BLIP vẫn giữ được tính thống nhất: hiểu ảnh tốt hơn thì captioning cũng tốt hơn, vì caption chất lượng phụ thuộc rất mạnh vào mức căn chỉnh thị giác-ngôn ngữ ở tầng biểu diễn.

Điểm hạn chế là BLIP vẫn là mô hình pretrain tương đối nặng theo kiểu end-to-end, và chất lượng caption chịu ảnh hưởng nhiều bởi dữ liệu pretraining cùng quy trình bootstrap.

3. Mô hình BLIP-2

3.1. Động cơ phát triển

BLIP-2 xuất phát từ một nhận xét rất thực tế: pretraining vision-language kiểu end-to-end ngày càng đắt, trong khi cộng đồng đã có sẵn hai tài sản rất mạnh là image encoder tiền huấn luyện tốt và large language model rất mạnh. Câu hỏi là: có thể nối hai thứ đó với chi phí thấp hơn mà vẫn captioning tốt không? BLIP-2 trả lời là có.

Bài báo cho rằng vấn đề cốt lõi không nằm ở việc có encoder ảnh hay LLM mạnh, mà nằm ở **modality gap**: LLM chưa từng "nhìn thấy ảnh", nên nếu đóng băng LLM thì phải có một cơ chế trung gian đủ tốt để trích đúng thông tin thị giác và diễn dịch nó theo ngôn ngữ mà LLM hiểu được.

3.2. Ý tưởng trung tâm của BLIP-2

BLIP-2 dùng một mô-đun nhẹ tên là **Q-Former (Querying Transformer)** làm cầu nối giữa frozen image encoder và frozen LLM. Mô hình được huấn luyện theo hai giai đoạn:

- Giai đoạn 1: học biểu diễn vision-language từ image encoder đóng băng,
- Giai đoạn 2: học sinh ngôn ngữ từ biểu diễn thị giác sang LLM đóng băng.

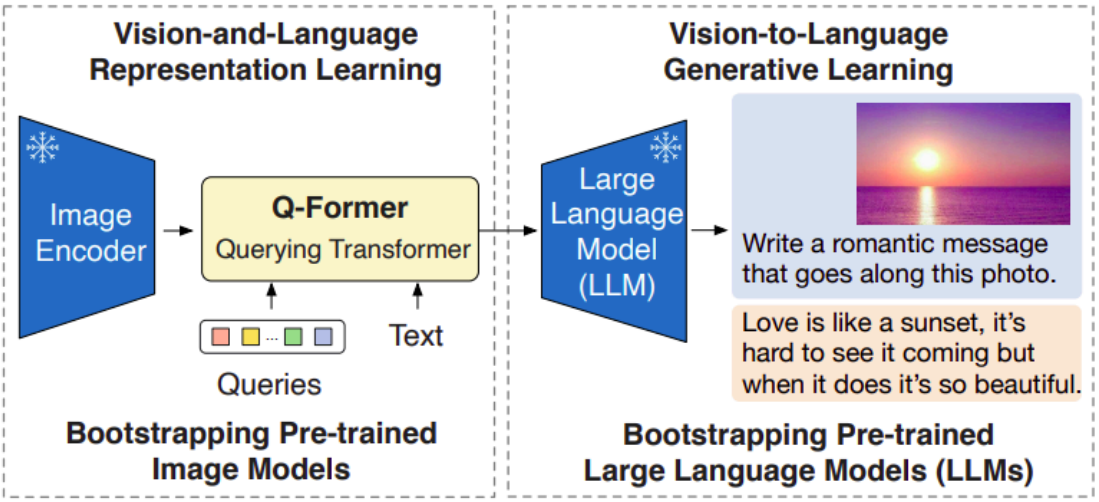

3.3. Q-Former: bản chất hoạt động

Q-Former là phần trainable chính. Nó gồm hai transformer submodule chia sẻ self-attention: một nhánh tương tác với image encoder để trích đặc trưng ảnh, và một nhánh văn bản có thể đóng vai text encoder hoặc text decoder.

Điểm đặc biệt là BLIP-2 dùng một số lượng hữu hạn **learnable queries**. Các query này không phải token văn bản thật, mà là vector học được, dùng để "hỏi" image encoder xem phần nào của ảnh là quan trọng. Kết quả là Q-Former xuất ra một tập đặc trưng cố định kích thước nhỏ hơn nhiều so với đặc trưng ảnh gốc. Theo bài báo, trong thí nghiệm họ dùng 32 queries, mỗi query có chiều 768; như vậy đầu ra chỉ cỡ 32×768, nhỏ hơn đáng kể so với feature map của ViT-L/14.

Bản chất của Q-Former là một **information bottleneck**. Nó ép mô hình chỉ chuyển sang phía ngôn ngữ phần thông tin thị giác có ích nhất. Đây là điểm rất có lợi cho image captioning: caption tốt không cần toàn bộ tín hiệu pixel, mà cần một tập tín hiệu cô đọng nhưng đủ giàu ngữ nghĩa.

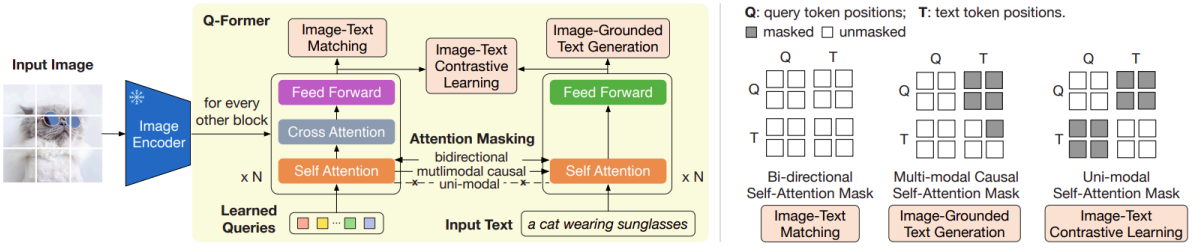

3.4. Giai đoạn 1: học biểu diễn vision-language

Ở giai đoạn đầu, BLIP-2 kết nối Q-Former với image encoder đóng băng rồi tối ưu ba loss:

- **ITC** để căn chỉnh biểu diễn ảnh-văn bản.
- **ITG** để học sinh văn bản có điều kiện theo ảnh ngay trong Q-Former.
- **ITM** để học đối sánh fine-grained giữa ảnh và văn bản.

Ba objective này rất giống tinh thần BLIP, nhưng khác ở chỗ mọi thứ phải đi qua bottleneck là Q-Former thay vì huấn luyện end-to-end toàn bộ pipeline.

3.5. Giai đoạn 2: học sinh ngôn ngữ từ ảnh sang LLM

Sau khi Q-Former biết trích đặc trưng thị giác phù hợp ngôn ngữ, BLIP-2 nối đầu ra Q-Former sang LLM qua một fully-connected layer để chiếu về đúng chiều embedding của LLM. Các embedding này được ghép ở đầu chuỗi như soft visual prompts.

Bài báo xét hai kiểu LLM:

- **decoder-only** như OPT: huấn luyện language modeling loss;
- **encoder-decoder** như FlanT5: huấn luyện prefix language modeling, tách văn bản thành prefix và suffix.

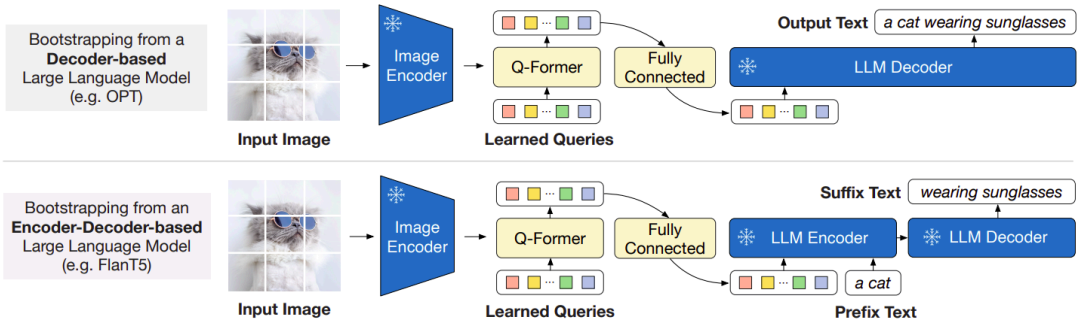

3.6. Dữ liệu và thiết lập pretraining của BLIP-2

BLIP-2 dùng cùng nền dữ liệu 129M ảnh như BLIP, gồm COCO, Visual Genome, CC3M, CC12M, SBU và 115M ảnh từ LAION400M. Quan trọng hơn, BLIP-2 tiếp tục tận dụng CapFilt từ BLIP để tạo caption tổng hợp cho web images. Cụ thể, bài báo nói họ sinh 10 caption bằng BLIPlarge, xếp hạng chúng cùng caption gốc bằng CLIP ViT-L/14, rồi giữ lại top-2 caption cho mỗi ảnh.

Điểm này cho thấy BLIP-2 tuy là một thế hệ mới nhưng về mặt dữ liệu vẫn kế thừa trực tiếp tư tưởng của BLIP, nhưng về mặt dữ liệu nó kế thừa trực tiếp tư tưởng của BLIP rằng captioning tốt phụ thuộc rất mạnh vào chất lượng và tính giàu ngữ nghĩa của cặp ảnh-văn bản.

Về backbone, bài báo thử CLIP ViT-L/14 và EVA-CLIP ViT-g/14 làm image encoder; với LLM thì thử OPT và FlanT5. Giai đoạn 1 huấn luyện 250k steps, giai đoạn 2 huấn luyện 80k steps. Nhờ đóng băng phần lớn backbone, chi phí huấn luyện giảm đáng kể. Bài báo nêu rằng mô hình lớn nhất với ViT-g và FlanT5-XXL trên một máy 16 A100 40GB cần dưới 6 ngày cho stage 1 và dưới 3 ngày cho stage 2.

3.7. BLIP-2 cho image captioning

Models	#Trainable Params	NoCaps Zero-shot (validation set)								COCO Fine-tuned Karpathy test	
		in-domain		near-domain		out-domain		overall			
		C	S	C	S	C	S	C	S	B@4	C
OSCAR (Li et al., 2020)	345M	-	-	-	-	-	-	80.9	11.3	37.4	127.8
VinVL (Zhang et al., 2021)	345M	103.1	14.2	96.1	13.8	88.3	12.1	95.5	13.5	38.2	129.3
BLIP (Li et al., 2022)	446M	114.9	15.2	112.1	14.9	115.3	14.4	113.2	14.8	40.4	136.7
OFA (Wang et al., 2022a)	930M	-	-	-	-	-	-	-	-	**43.9**	145.3
Flamingo (Alayrac et al., 2022)	10.6B	-	-	-	-	-	-	-	-	-	138.1
SimVLM (Wang et al., 2021b)	~1.4B	113.7	-	110.9	-	115.2	-	112.2	-	40.6	143.3
BLIP-2 ViT-g $OPT_{2.7B}$	1.1B	123.0	15.8	117.8	15.4	123.4	**15.1**	119.7	15.4	43.7	**145.8**
BLIP-2 ViT-g $OPT_{6.7B}$	1.1B	**123.7**	15.8	119.2	15.3	124.4	14.8	121.0	15.3	43.5	145.2
BLIP-2 ViT-g $FlanT5_{XL}$	1.1B	**123.7**	**16.3**	**120.2**	**15.9**	**124.8**	**15.1**	**121.6**	**15.8**	42.4	144.5

Biến thể BLIP-2 ViT-g OPT2.7B đạt 145.8 CIDEr trên COCO Karpathy test; biến thể BLIP-2 ViT-g FlanT5XL đạt 121.6 CIDEr và 15.8 SPICE trên NoCaps overall. So với BLIP trước đó, các chỉ số này được cải thiện rõ.

Điều đáng nói là BLIP-2 không chỉ captioning theo kiểu "mô tả ảnh đơn thuần". Nhờ kết nối với LLM, nó còn có khả năng instructed zero-shot image-to-text generation.

3.8. Ưu điểm và hạn chế của BLIP-2

Ưu điểm lớn nhất là hiệu quả tính toán: phần trainable nhỏ hơn nhiều so với các mô hình end-to-end lớn, nhưng chất lượng rất mạnh. Với riêng image captioning, ưu điểm là:

- tận dụng tri thức sẵn có của LLM nên câu sinh ra tự nhiên hơn,
- có thể caption có điều khiển bằng prompt,
- dễ mở rộng bằng cách thay image encoder hoặc LLM tốt hơn.

Hạn chế:

- chưa thể hiện tốt in-context learning với nhiều cặp ảnh-văn bản trong cùng ngữ cảnh,
- caption hoặc câu trả lời có thể sai vì tri thức LLM không chính xác, suy luận sai hướng, hoặc thiếu cập nhật,
- do dùng frozen LLM, mô hình kế thừa rủi ro về thiên kiến, ngôn ngữ không phù hợp, hay rò rỉ thông tin nhạy cảm từ LLM nền.

4. So sánh BLIP và BLIP-2 trong bài toán image captioning

Nếu nhìn từ góc độ captioning thuần túy, BLIP và BLIP-2 có cùng mục tiêu nhưng triết lý khác nhau.

BLIP là mô hình thị giác-ngôn ngữ thống nhất, học captioning ngay trong một kiến trúc MED. Sức mạnh của nó nằm ở sự đồng thiết kế giữa kiến trúc và dữ liệu. Nó làm tốt captioning nhờ decoder được huấn luyện trực tiếp và nhờ CapFilt cải thiện dữ liệu.

BLIP-2 thì xem captioning như một dạng sinh ngôn ngữ có điều kiện trên ảnh, rồi tận dụng LLM đã rất mạnh về ngôn ngữ. Nó không cố học lại toàn bộ từ đầu, mà học cách trích "đúng phần cần nói" từ ảnh rồi chuyển nó sang ngôn ngữ mà LLM hiểu.

Nói ngắn gọn hơn:

- BLIP mạnh ở tính thống nhất và chiến lược xử lý dữ liệu.

- BLIP-2 mạnh ở tận dụng backbone có sẵn và nối ảnh với LLM một cách hiệu quả.

Với image captioning truyền thống, BLIP đã rất mạnh. Nhưng với captioning mở rộng, có điều khiển bằng câu lệnh tự nhiên, hoặc cần tận dụng sức mạnh của LLM, BLIP-2 thể hiện hướng phát triển thuyết phục hơn.