HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN I

BÁO CÁO HẰNG TUẦN MÔN
THỰC TẬP CƠ SỞ

Giảng viên hướng dẫn : TS. Kim Ngọc Bách
Sinh viên thực hiện : Mã sinh viên
Nguyễn Việt Quang : B23DCCN691

Hà Nội – 2026

I. Tối ưu hóa Pipeline, tái cấu trúc dữ liệu và xử lý Tokenizer tiếng Việt

1. Mở đầu

Trong tuần này, trong quá trình huấn luyện và đánh giá mô hình trên môi trường Kaggle, em đã phát hiện một vấn đề nghiêm trọng: mô hình sinh văn bản tiếng Việt không có dấu thanh. Đây là lần đầu tiên vấn đề này được ghi nhận thông qua quá trình suy luận trên tập test. Mặc dù nội dung câu sinh ra tương đối hợp lý về mặt ngữ nghĩa, việc thiếu dấu tiếng Việt đã làm sai lệch hoàn toàn khi so sánh với nhãn tham chiếu, kéo các chỉ số đánh giá xuống mức rất thấp.

Song song với đó, quá trình huấn luyện cũng cho thấy một số hạn chế liên quan đến hiệu năng xử lý dữ liệu và nguy cơ overfitting khi fine-tuning. Do đó, trong tuần này, em tiến hành tái cấu trúc dữ liệu ở môi trường Local, tối ưu hóa pipeline, thử nghiệm siêu tham số và thực hiện fine-tuning đầy đủ trên Kaggle để đánh giá toàn diện mô hình.

2. Mục tiêu thực hiện

Mục tiêu chính bao gồm: làm sạch và chuẩn hóa dữ liệu ảnh; thử nghiệm và điều chỉnh siêu tham số trên môi trường Local; triển khai fine-tuning đầy đủ trên Kaggle; đánh giá mô hình và phân tích nguyên nhân dẫn đến lỗi biểu diễn tiếng Việt.

3. Môi trường và thiết lập thực hiện

Các công việc được tách thành hai môi trường rõ ràng. Trên máy cá nhân (GPU GTX 1650 4GB), em chỉ thực hiện xử lý dữ liệu và thử nghiệm siêu tham số. Cụ thể, dữ liệu ảnh được resize và tái mã hóa để loại bỏ lỗi metadata, đồng thời tiến hành các thử nghiệm cấu hình huấn luyện.

Quá trình fine-tuning chính thức được thực hiện trên Kaggle với GPU Tesla T4 (16GB VRAM). Nhờ dung lượng bộ nhớ lớn hơn, em sử dụng trực tiếp batch size 64 mà không cần áp dụng Gradient Accumulation như trong giai đoạn thử nghiệm Local.

4. Nội dung thực hiện

4.1. Tái cấu trúc dữ liệu (Local)

Toàn bộ dữ liệu ảnh được xử lý offline bằng OpenCV, chuẩn hóa về kích thước 384x384. Quá trình này giúp loại bỏ hoàn toàn các lỗi metadata trong file ảnh và giảm tải cho

CPU trong quá trình huấn luyện. Đây là bước tiền xử lý quan trọng trước khi đưa dữ liệu lên Kaggle để huấn luyện.

4.2. Thử nghiệm siêu tham số (Local)

Trên môi trường Local, em tiến hành thử nghiệm các cấu hình huấn luyện nhằm tìm ra thiết lập phù hợp với mô hình, bao gồm batch size nhỏ, mixed precision và các thông số optimizer như learning_rate=5e-5. Các thử nghiệm này đóng vai trò định hướng trước khi chạy huấn luyện quy mô lớn trên Kaggle.

4.3. Fine-tuning mô hình trên Kaggle

Quá trình fine-tuning đầy đủ được thực hiện trong 10 epoch với batch size 64. Kết quả cho thấy validation loss giảm ổn định trong các epoch đầu và đạt giá trị tốt nhất tại epoch 4 (Val Loss = 1.4938). Sau đó, validation loss bắt đầu tăng dần trong khi train loss tiếp tục giảm, thể hiện rõ hiện tượng overfitting.

Cụ thể, train loss giảm liên tục từ 1.9382 xuống 0.2904 qua 10 epoch, trong khi validation loss tăng từ 1.4938 (epoch 4) lên 2.2563 (epoch 10). Điều này cho thấy mô hình bắt đầu ghi nhớ dữ liệu huấn luyện và mất khả năng tổng quát hóa. Do đó, mô hình tại epoch 4 được lựa chọn làm checkpoint tối ưu.

4.4. Đánh giá trên tập test và phát hiện vấn đề tiếng Việt không dấu

Trong quá trình suy luận trên tập test, mô hình sinh ra các câu mô tả có nội dung phù hợp với ảnh nhưng toàn bộ dấu tiếng Việt bị loại bỏ. Ví dụ như: “nhung thua ruong bac thang chin vang co xanh xen ke nhau”, “mot cua tiem co bang hieu mau hong…”.

Phân tích nguyên nhân cho thấy Tokenizer mặc định của mô hình được thiết kế cho tiếng Anh và có cơ chế loại bỏ dấu (strip accents), dẫn đến việc mô hình không thể học và sinh đúng các ký tự tiếng Việt có dấu.

Hệ quả là các chỉ số đánh giá bị suy giảm nghiêm trọng do sự khác biệt hình thức giữa dự đoán và nhãn tham chiếu. Kết quả trên tập test như sau:

- BLEU-4 Score: 0.00
- ROUGE-L Score: 4.34
- METEOR Score: 2.63

Các chỉ số này không phản ánh chính xác chất lượng ngữ nghĩa mà chủ yếu bị ảnh hưởng bởi lỗi Tokenizer.

4.5. Định hướng khắc phục

Để giải quyết vấn đề, cần mở rộng Tokenizer bằng cách bổ sung đầy đủ các ký tự tiếng Việt có dấu và điều chỉnh lại embedding của mô hình. Đây là bước cần thiết để đảm bảo mô hình có thể học và sinh văn bản tiếng Việt chính xác trong các giai đoạn tiếp theo.

5. Kết quả và nhận xét

Pipeline huấn luyện đã được hoàn thiện và hoạt động ổn định. Việc tách biệt rõ ràng giữa môi trường Local và Kaggle giúp tối ưu hiệu quả phát triển và huấn luyện. Đồng thời, việc phát hiện hiện tượng overfitting và vấn đề Tokenizer là hai kết quả quan trọng, định hướng cho bước cải tiến tiếp theo.

6. Kết luận

Trong tuần này, em đã hoàn thành việc tiền xử lý dữ liệu, thử nghiệm siêu tham số, thực hiện fine-tuning và đánh giá mô hình. Kết quả cho thấy mô hình đạt hiệu quả nhất tại epoch 4 nhưng vẫn tồn tại hạn chế trong biểu diễn tiếng Việt do Tokenizer. Trong giai đoạn tiếp theo, em sẽ tập trung điều chỉnh Tokenizer và huấn luyện lại mô hình nhằm cải thiện chất lượng đầu ra.