HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN I

BÁO CÁO HẰNG TUẦN MÔN
THỰC TẬP CƠ SỞ

Giảng viên hướng dẫn : TS. Kim Ngọc Bách
Sinh viên thực hiện : Mã sinh viên
Nguyễn Việt Quang : B23DCCN691

Hà Nội – 2026

I. Thử nghiệm mô hình BLIP cho bài toán image captioning

1. Mở đầu

Trong tiến trình thực hiện đề tài Finetune mô hình BLIP theo bộ dữ liệu tiếng Việt và xây dựng hệ thống mô tả thế giới thực cho người khiếm thị, một bước rất quan trọng ở giai đoạn đầu là kiểm tra khả năng hoạt động thực tế của mô hình nền trước khi tiến hành huấn luyện bổ sung. Đề tài của bạn cũng xác định rõ mục tiêu là sử dụng BLIP cho bài toán mô tả ảnh và sau đó tinh chỉnh theo dữ liệu tiếng Việt để phục vụ ứng dụng hỗ trợ người khiếm thị.

Vì vậy, trong tuần này, nội dung chính được thực hiện là thử nghiệm mô hình BLIP tiền huấn luyện trên bài toán image captioning. Trong tuần này, phần thử nghiệm được thực hiện nhằm kiểm tra xem mô hình BLIP có thể chạy ổn định trên môi trường hiện tại hay không, chất lượng caption bước đầu đạt đến mức nào, và mô hình gốc còn thiếu gì trước khi chuyển sang giai đoạn finetune tiếng Việt.

Về mặt bản chất, image captioning là quá trình chuyển tín hiệu thị giác thành một chuỗi ngôn ngữ tự nhiên. Với BLIP, việc này được thực hiện trong một khung vision-language pretraining thống nhất, nơi mô hình vừa học biểu diễn chung giữa ảnh và văn bản, vừa có nhánh sinh ngôn ngữ để tạo caption. Bài báo gốc nhấn mạnh BLIP được thiết kế để phục vụ cả understanding lẫn generation, đồng thời tận dụng dữ liệu web nhiễu bằng cơ chế bootstrapping caption và filtering.

2. Mục tiêu thử nghiệm

Thử nghiệm tuần này tập trung vào mô hình Salesforce/blip-image-captioning-base dưới dạng tiền huấn luyện. Mục tiêu cụ thể gồm ba phần.

Phần thứ nhất là kiểm tra khả năng chạy inference từ đầu đến cuối: nạp mô hình, tiền xử lý ảnh, sinh caption, và ghi nhận kết quả đầu ra. Model card chính thức của checkpoint này cho biết đây là biến thể BLIP được dùng cho bài toán image captioning.

Phần thứ hai là quan sát chất lượng caption trên một số ảnh mẫu. Ở bước này, trọng tâm không phải là điểm số BLEU hay CIDEr, mà là xem câu sinh ra có nhận diện đúng đối tượng chính, hành động chính và bối cảnh cơ bản của ảnh hay không.

Phần thứ ba là phân tích giới hạn của mô hình gốc trước khi bước sang finetune dữ liệu tiếng Việt. Đây là bước cần thiết vì BLIP gốc chủ yếu được huấn luyện trên dữ liệu ảnh-văn bản quy mô lớn thiên về tiếng Anh, nên nếu dùng trực tiếp cho ứng dụng tiếng Việt thì đầu ra thường chưa đáp ứng được yêu cầu của đề tài.

3. Môi trường và thiết lập thử nghiệm

Môi trường thực hiện gồm Python, PyTorch, Transformers và Pillow. Cách triển khai dựa trên processor và mô hình BLIP được Hugging Face cung cấp chính thức trong thư viện Transformers. Tài liệu mô hình của Transformers mô tả BLIP như một khung vision-language pretraining phục vụ cả understanding và generation, đồng thời hỗ trợ các lớp xử lý cần thiết cho captioning.

Trong thử nghiệm này, ảnh đầu vào được đưa qua BlipProcessor để chuyển sang tensor và chuẩn hóa đúng định dạng. Sau đó BlipForConditionalGeneration sinh caption bằng cơ chế generate. Về bản chất, đây là luồng chạy suy luận chuẩn của một mô hình image-to-text: encoder thị giác trích xuất đặc trưng ảnh, rồi decoder ngôn ngữ sinh ra chuỗi mô tả có điều kiện theo nội dung ảnh. Cách làm này phù hợp với mục tiêu tuần hiện tại, vì nó cho phép kiểm tra trực tiếp chất lượng caption mà chưa cần can thiệp vào quá trình huấn luyện.

4. Nội dung thực hiện thử nghiệm

Trong tuần này, quá trình thử nghiệm được triển khai theo các bước sau.

Trước hết, em cài đặt môi trường và kiểm tra khả năng sử dụng thiết bị tính toán. Sau đó em nạp checkpoint **Salesforce/blip-image-captioning-base**, chuẩn bị thư mục ảnh mẫu và xây dựng chương trình suy luận tự động trên nhiều ảnh. Mỗi ảnh được đọc bằng Pillow, chuyển qua processor của BLIP, rồi đưa vào mô hình để sinh caption bằng beam search.

Tiếp theo, em ghi nhận caption đầu ra và thời gian suy luận cho từng ảnh. Việc đo thời gian này có ý nghĩa thực tế vì hệ thống cuối cùng hướng tới một ứng dụng hỗ trợ người khiếm thị, nên ngoài độ đúng ngữ nghĩa, thời gian phản hồi cũng là một tiêu chí quan trọng ở mức demo. Điều này cũng phù hợp với yêu cầu phi chức năng trong đề cương, nơi hệ thống cần phản hồi ở mức chấp nhận được dù chưa cần real-time nghiêm ngặt.

5. Kết quả thử nghiệm bước đầu

Thử nghiệm được thực hiện với mô hình **Salesforce/blip-image-captioning-base** trên môi trường có **GPU NVIDIA GeForce GTX 1650 4GB**, mô hình được nạp và chạy ở chế độ cuda. Kết quả thực tế cho thấy pipeline suy luận hoạt động ổn định: mô hình được tải thành công, ảnh đầu vào được xử lý đúng định dạng và hệ thống sinh được caption cho toàn bộ tập ảnh thử nghiệm mà không xảy ra lỗi trong quá trình generate.

Trong lần thử nghiệm này, em sử dụng 5 ảnh mẫu để kiểm tra chất lượng mô tả của mô hình. Kết quả caption sinh ra như sau:

```
============================================================
Image: 00000000464.jpg
Caption: a small house in the middle of a forest
Inference time: 0.6921 seconds
============================================================
Image: 00000000467.jpg
Caption: a crowd of people walking down a street in front of a chur
Inference time: 0.3501 seconds
============================================================
Image: 00000000473.jpg
Caption: a crowd of people standing under a tree
Inference time: 0.2906 seconds
============================================================
Image: 00000000475.jpg
Caption: people are shopping in a store filled with boxes
Inference time: 0.2977 seconds
============================================================
Image: 00000000476.jpg
Caption: a group of people walking down a street next to a fruit st
Inference time: 0.3505 seconds
============================================================
Average inference time: 0.3962 seconds/image
```

Hình 5.1. *Kết quả chạy thử nghiệm*

Hình 5.2. Kết quả caption trên ảnh 00000000464.jpg: "a small house in the middle of a forest".

Hình 5.3. Kết quả caption trên ảnh 00000000467.jpg: "a crowd of people walking down a street in front of a church".

Hình 5.4. Kết quả caption trên ảnh 00000000473.jpg: "a crowd of people standing under a tree".

Hình 5.5. Kết quả caption trên ảnh 00000000475.jpg: "people are shopping in a store filled with boxes".

Hình 5.6. Kết quả caption trên ảnh 00000000476.jpg: "a group of people walking down a street next to a fruit stand".

Thời gian suy luận tương ứng trên từng ảnh lần lượt là 0.6921 giây, 0.3501 giây, 0.2906 giây, 0.2977 giây và 0.3505 giây, với thời gian trung bình đạt 0.3962 giây/ảnh.

Với cấu hình phần cứng đang sử dụng, đây là tốc độ phản hồi tương đối tốt cho một hệ thống thử nghiệm ở mức demo.

Xét về mặt nội dung, các caption sinh ra cho thấy mô hình đã nhận diện được đối tượng trung tâm và bối cảnh tổng quát của ảnh. Với ảnh có bố cục rõ ràng, mô hình mô tả khá đúng nội dung chính, chẳng hạn như trường hợp ảnh ngôi nhà giữa rừng hoặc cảnh người đi bộ trên phố. Ở các ảnh có nhiều người và nhiều thành phần thị giác cùng xuất hiện, mô hình vẫn giữ được khả năng mô tả tổng quát, tuy nhiên câu sinh ra còn thiên về mức khái quát hơn là mô tả chi tiết.

Một điểm cần lưu ý là toàn bộ caption đầu ra đều ở tiếng Anh. Kết quả này phản ánh đúng đặc điểm của mô hình BLIP tiền huấn luyện: mô hình có năng lực captioning tốt trên dữ liệu phổ thông, nhưng đầu ra mặc định vẫn gắn mạnh với miền dữ liệu huấn luyện gốc, chủ yếu là tiếng Anh. Điều này cũng cho thấy nếu đặt trong mục tiêu của đề tài là xây dựng hệ thống mô tả ảnh bằng tiếng Việt cho người khiếm thị, thì việc finetune trên dữ liệu tiếng Việt là bước tiếp theo có tính bắt buộc. Mục tiêu này cũng phù hợp với định hướng đã nêu trong đề cương, nơi mô hình BLIP được chọn làm nền tảng để tinh chỉnh cho bài toán mô tả ảnh tiếng Việt.

6. Nhận xét về mô hình BLIP qua thử nghiệm

Qua kết quả chạy thực tế, có thể thấy BLIP là một mô hình phù hợp cho giai đoạn khởi đầu của đề tài. Ưu điểm đầu tiên là quá trình triển khai tương đối thuận lợi. Việc sử dụng checkpoint tiền huấn luyện sẵn cho phép nhanh chóng xây dựng được pipeline hoàn chỉnh từ ảnh đầu vào đến câu mô tả đầu ra, nhờ đó rút ngắn đáng kể thời gian thử nghiệm ban đầu.

Ưu điểm thứ hai là mô hình cho chất lượng caption ở mức khá đối với các ảnh thông dụng. Dù chưa đi sâu vào đánh giá định lượng bằng các thước đo như BLEU, CIDEr hay SPICE, kết quả quan sát trực tiếp cho thấy mô hình đã nhận diện được khá đúng các thực thể chính và bối cảnh cơ bản của ảnh. Điều này cho thấy phần căn chỉnh giữa đặc trưng thị giác và biểu diễn ngôn ngữ của BLIP hoạt động hiệu quả ở mức suy luận.

Tuy nhiên, thử nghiệm cũng bộc lộ một số hạn chế rõ rệt. Trước hết, caption đầu ra hoàn toàn bằng tiếng Anh, trong khi mục tiêu của đề tài là mô tả ảnh bằng tiếng Việt. Điều này có nghĩa là mô hình gốc chưa thể sử dụng trực tiếp cho ứng dụng cuối cùng. Bên cạnh đó, nội dung mô tả còn tương đối ngắn và thiên về mô tả tổng quát. Với các

ảnh có nhiều đối tượng hoặc giàu quan hệ ngữ nghĩa, mô hình chưa thể hiện được mức diễn đạt đủ chi tiết để trở thành một công cụ hỗ trợ thực sự hữu ích cho người khiếm thị.

Từ góc nhìn ứng dụng, đây là một nhận xét quan trọng. Một hệ thống hỗ trợ người khiếm thị không chỉ cần "nhìn đúng" mà còn cần "mô tả đủ dùng", nghĩa là câu sinh ra phải có giá trị định hướng hoặc cung cấp thông tin thực sự hữu ích cho người sử dụng. Trong khi đó, caption của mô hình BLIP gốc hiện mới dừng ở mức mô tả ngắn gọn nội dung trung tâm của ảnh. Vì vậy, bước finetune không chỉ nhằm chuyển ngôn ngữ đầu ra sang tiếng Việt, mà còn nhằm làm cho mô hình thích nghi tốt hơn với kiểu mô tả mong muốn của bài toán thực tế.

Ngoài ra, trong quá trình chạy mô hình xuất hiện một số cảnh báo từ thư viện liên quan đến processor nhanh, tied weights và một khóa position_ids được đánh dấu là UNEXPECTED. Tuy vậy, các cảnh báo này không làm gián đoạn quá trình suy luận và không ảnh hưởng trực tiếp đến việc mô hình sinh caption trong lần thử nghiệm hiện tại. Vì thế, ở giai đoạn này có thể xem đây chủ yếu là các cảnh báo mang tính tương thích triển khai, chưa phải vấn đề cốt lõi của mô hình.

7. Kết luận

Trong tuần này, em đã hoàn thành bước thử nghiệm mô hình BLIP tiền huấn luyện cho bài toán image captioning trên môi trường có GPU. Kết quả thực nghiệm cho thấy mô hình hoạt động ổn định, sinh được caption cho toàn bộ tập ảnh thử nghiệm, với thời gian suy luận trung bình khoảng **0.3962 giây/ảnh** trên **NVIDIA GeForce GTX 1650 4GB**. Điều này cho thấy hướng tiếp cận bằng BLIP là khả thi về mặt triển khai kỹ thuật trong phạm vi đề tài.

Về mặt chất lượng, mô hình đã thể hiện khả năng mô tả đúng nội dung chính của ảnh ở mức cơ bản, đặc biệt với các ảnh có bố cục rõ và đối tượng nổi bật. Tuy nhiên, đầu ra hiện vẫn là tiếng Anh và nội dung mô tả còn ngắn, chưa đáp ứng đầy đủ yêu cầu của một hệ thống mô tả ảnh bằng tiếng Việt phục vụ người khiếm thị. Từ kết quả này có thể khẳng định rằng BLIP là một nền tảng ban đầu phù hợp, nhưng để tiến gần đến mục tiêu của đề tài thì cần tiếp tục thực hiện bước chuẩn bị dữ liệu tiếng Việt và finetune mô hình trong giai đoạn tiếp theo. Nội dung này cũng bám sát phạm vi và định hướng triển khai đã được xác định trong đề cương dự án.

TÀI LIỆU THAM KHẢO

[1] J. Li, D. Li, C. Xiong, and S. C. H. Hoi, “BLIP: Bootstrapping Language-Image Pre-training for Unified Vision-Language Understanding and Generation,” Proceedings of the 39th International Conference on Machine Learning (ICML), 2022.

[2] J. Li, D. Li, S. Savarese, and S. C. H. Hoi, “BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models,” Proceedings of the 40th International Conference on Machine Learning (ICML), 2023.

[3] Hugging Face, “BLIP model documentation,” Transformers Documentation.

[4] Salesforce, “Salesforce/blip-image-captioning-base,” Hugging Face Model Card.